

**Д.В. Маршаков, Д.В. Фатхи**

## **МОДЕЛЬ АППАРАТНОЙ РЕАЛИЗАЦИИ ИСКУССТВЕННОГО НЕЙРОНА НА ОСНОВЕ ЦВЕТНЫХ ВРЕМЕННЫХ СЕТЕЙ ПЕТРИ**

*В работе рассматриваются основные принципы построения цветных временных сетей Петри для моделирования и анализа свойств искусственных нейронных сетей. Представлена модель искусственного нейрона на основе цветных временных сетей Петри и дано формальное описание функционирования модели.*

Искусственные нейронные сети, аппаратная реализация, моделирование, сети Петри, сигмоидальная функция активации

**D.V. Marshakov, D.V. Fatkhi**

## **THE MODEL OF THE HARDWARE IMPLEMENTATION OF ARTIFICIAL NEURON BASED ON COLORED TIMED PETRI NETS**

*The paper deals with the basic principles of colored timed Petri nets as a tool for modeling and analyzing the properties of artificial neural networks. The model of artificial neuron based on colored timed Petri nets and a formal description of a functioning model are given.*

Artificial neural networks, hardware implementation, simulation, Petri nets, sigmoid activation function

### **Введение**

Современные искусственные нейронные сети (ИНС) в силу своих способностей к моделированию нелинейных процессов, обобщению, работе с зашумленными данными и т.д. находят применение во многих прикладных областях. При этом все более возрастает удельных вес аппаратных нейросетевых реализаций. Это связано с требованиями к обеспечению высоких скоростей решения сложных задач с использованием массового параллелизма [1, 2], с которыми пока не справляются традиционные компьютеры.

Одной из перспективных аппаратных реализаций ИНС является построение их на основе ПЛИС – матричных структур, обеспечивающих параллельную обработку информации и обладающих высокой степенью интеграции, масштабируемостью, развитыми средствами проектирования, реализации выполнения алгоритмов обучения [1-4].

Для правильного воплощения ИНС до её реализации необходимо предварительное моделирование структуры и поведения нейронов сети.

Мощным средством для моделирования параллельных и распределенных процессов являются сети Петри [5]. С помощью сетей Петри и их модификаций можно наглядно представить динамику функционирования систем и составляющих их элементов.

Применение цветных сетей Петри в контексте моделирования ИНС рассматривается в работах [6, 7]. В рассматриваемых моделях используются только пороговые функции активации (так называемые пороговые логические элементы), в которых обработка данных сводится к формированию на выходе бинарных дискретных сигналов. ИНС с пороговой функцией активации, они обладают рядом недостатков, среди которых наиболее существенным является насыщение нейронов от больших значений входных сигналов.

Более приемлемой в практике моделью ИНС является модель, состоящая из нейронов с непрерывной (как правило, сигмоидальной) функцией активации [1, 3, 4]. При этом пространство решений, в котором работает такая сеть, не ограничивается дискретными значениями и состоит из полного спектра возможных входов и их значений, благодаря чему сеть способна аппроксимировать практически любую функциональную зависимость. Кроме того, сигмоидальная функция активации обладает свойством усиливать слабые сигналы и предотвращает насыщение нейрона от больших сигналов [8].

Необходимо отметить, что в ИНС с пороговыми элементами обучение производится лишь на её модели, заноса полученные весовые коэффициенты в память кристалла на этапе проектирования. Использование в аппаратных реализациях многослойных нейронных сетей нейронов с сигмоидальной функцией активации может позволить производить обучение нейросети на кристалле в реальном масштабе времени.

В [9] отмечается, что при проектировании ИНС особое внимание современными разработчиками уделяется реализации ИНС с нейронами, обладающими сигмоидальной функцией активации.

Для исключения указанных недостатков ИНС с пороговой функцией, а также для обеспечения обучения аппаратных реализаций ИНС в реальном масштабе времени, необходима разработка сетевой модели ИНС с реализацией сигмоидальной функции активации.

### 1. Математическая модель искусственного нейрона

На рис. 1 представлена модель нейрона, лежащая в основе искусственных нейронных сетей. В состав нейрона входят умножители (синапсы), сумматор и устройство, реализующее функцию активации.

Синапсы выполняют скалярное произведение  $n$ -мерного вектора входных данных  $x = x_1, x_2, \dots, x_n$  и  $n$ -мерного вектора весовых данных  $w = w_1, w_2, \dots, w_n$ .

Сумматор выполняет сложение взвешенных входов:

$$\Sigma_j = \sum_{i=1}^n w_i x_i \quad (1)$$

где  $w_i$  ( $i=1, 2, \dots, n$ ) – вес синапса,  
 $x_i$  ( $i=1, 2, \dots, n$ ) – входной сигнал,  
 $n$  – число входов нейрона,  
 $j$  – номер нейрона.

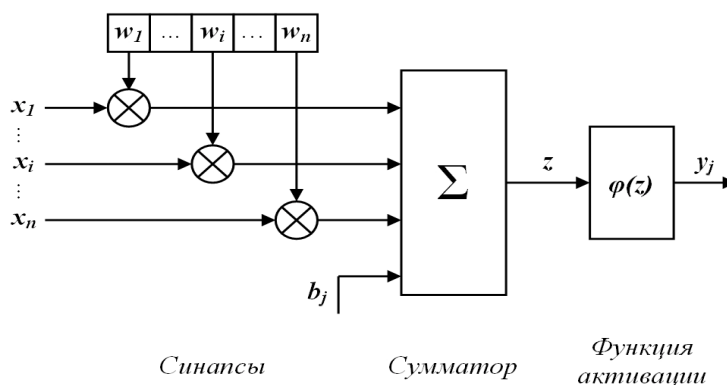


Рис. 1. Структура искусственного нейрона

Нейрон, показанный на рис. 1, дополнен скалярным смещением  $b_j$ . Смещение суммируется со взвешенными входами и приводит к сдвигу аргумента функции активации на величину  $b_j$ :

$$z = \Sigma_j + b_j, \quad (2)$$

где  $b_j$  – значение смещения.

Функция активации  $\varphi(z)$  определяет выходной сигнал нейрона. Сигмоидальная функция активации имеет вид (3).

$$y_j = \varphi(z) = \frac{1}{1 + e^{-z}} \quad (3)$$

Математическая модель нейрона описывается системой рассмотренных соотношений:

$$\begin{cases} z = \Sigma_j + b_j, \\ \varphi(z) = \frac{1}{1 + e^{-z}}; \end{cases} \quad (4)$$

## 2. Аппаратное представление искусственного нейрона

Один из вариантов архитектурного решения искусственного нейрона на основе ПЛИС Xilinx Spartan IIЕ рассмотрен в работе [4] и представлен на рис. 2.

Структура нейрона состоит из различных вычислительных подблоков. Для определения значения функции активации используется таблица (LUT), хранящаяся в блоке памяти RAM. В структуре содержится один умножитель (MUL) и один сумматор (ADD). Входные сигналы ( $input_i$ ) вводятся параллельно в ROM1. CONTROL UNIT, управляя стартовыми сигналами (start), конечными сигналами (reset) и счетчиком сигналов нейрона (num) координирует функции блоков, обеспечивает синхронизацию входных сигналов и соответствующих им весов. Первый входной сигнал и соответствующий ему вес сохраняется в ROM2, после чего блок MUL последовательно их перемножает и заносит в ROM3. Та же операция повторяется и для других входных сигналов, после чего сумматор ADD суммирует взвешенные входы (sum) и добавляет к ним значение смещения BIEST. Результат суммирования (sum\_out) поступает в таблицу определения значений сигмоидальной функции LUT, после чего полученное значение сохраняется в блоке OUT, подающем сигнал окончания процесса.

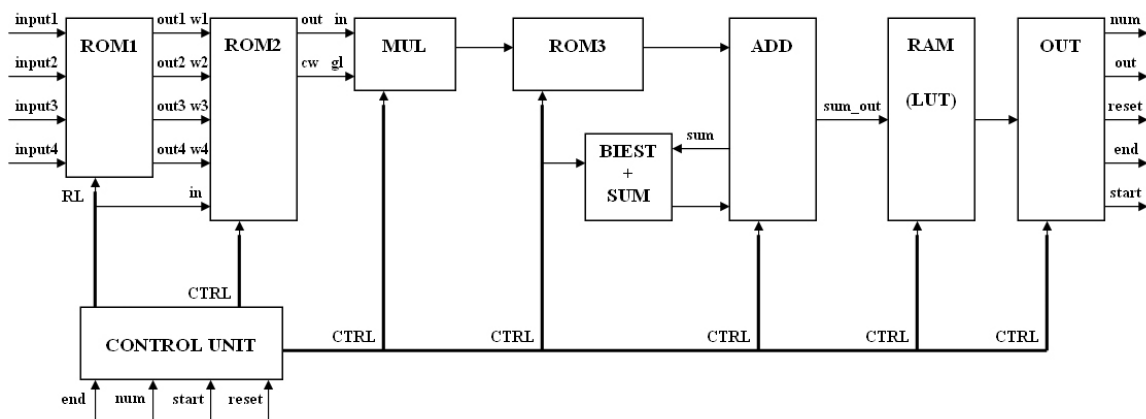


Рис. 2. Структурная схема аппаратного представления нейрона на основе ПЛИС Xilinx Spartan IIЕ

### 3. Модель искусственного нейрона на основе цветной временной сети Петри

В качестве модели искусственного нейрона предлагается модель, модифицирующая модели, рассмотренные в [6, 7], на основе цветных временных сетей Петри в контексте нейронных сетей с сигмоидальной функцией активации.

**Формальное определение модели.** Модифицированная цветная временная сеть Петри – *СТПНСИГ*, представляющая искусственный нейрон с сигмоидальной функцией активации задается следующим набором:

$$STPNNSIG = (P, T, A, M, C, F, H, \mu, \tau, OC, CT, SIG), \quad (5)$$

где:  $P = \{p_1, \dots, p_n\}$  – конечное непустое множество позиций;

$T = \{t_1, \dots, t_m\}$  – конечное непустое множество переходов;

$A$  – конечное непустое множество дуг такое, что  $A \subseteq (P \times T) \cup (T \times P)$ ;

$M$  – функция маркировки, определенная на  $P$  так, что для  $p \in P$   $M(p): C(p) \rightarrow Z$ , где  $Z$  – множество целых чисел;

$C$  – конечное множество цветов, состоящее из двух наборов цветов  $C(p)$  и  $C(t)$ , такое, что  $C = C(p) \cup C(t)$ :

- $C(p_j) = \{\langle \text{цвет}_{jp1}, \text{приоритет}_{jp1} \rangle, \langle \text{цвет}_{jp2}, \text{приоритет}_{jp2} \rangle, \dots, \langle \text{цвет}_{jpc}, \text{приоритет}_{jpc} \rangle\}$  – набор присвоения маркерам каждого места  $p \in P$  цветов и соответствующих им приоритетов, где  $p_c$  – число цветных маркеров в позиции  $p_j \in P$ ;
- $C(t_j) = \{\langle \text{цвет}_{jt1}, \text{приоритет}_{jt1} \rangle, \langle \text{цвет}_{jt2}, \text{приоритет}_{jt2} \rangle, \dots, \langle \text{цвет}_{jtc}, \text{приоритет}_{jtc} \rangle\}$  – набор присвоения маркерам цветов и соответствующих им приоритетов каждому переходу  $t \in T$  цветов, где  $t_c$  – количество цветов, связанных с переходом  $t_j \in T$ .

Цвета и их приоритеты связаны с каждой позицией  $C(p) \in C$  и каждым переходом  $C(t) \in C$  в сети. Для связи цвета с его приоритетом цвета определяются в порядке убывания приоритетов, а именно: красный ( $\kappa$ ), зеленый ( $\zeta$ ), синий ( $\varsigma$ ), черный ( $\chi$ ), желтый ( $\mathcal{J}$ ) и белый ( $\mathcal{B}$ ). Каждому приоритету этих цветов соответствует числовое обозначение в порядке убывания – 1, 2, 3, 4, 5 и 6, соответственно. Например, запись  $\langle \kappa, 1 \rangle$  отражает красный цвет с максимальным приоритетом.

$F$  – функция цветной кратности  $F(a): A(C) \rightarrow Z$ , описывающая тип и количество цветов, связанных с каждой дугой  $a \in A$ , где  $Z$  – множество целых чисел.

$H$  – множество ингибиторных дуг. При этом  $P_h = \{p_h \mid (p_h, t) \in H\}$  – множество ингибиторных позиций,  $p_h \in P_h$  и  $p_h \subseteq P_h$ . Функция  $H(p_h \langle \text{цвет} \rangle, t): H \rightarrow C(p_h) \times C(t)$  описывает каждую ингибиторную дугу  $H(p_h \langle \text{цвет} \rangle, t)$  во множестве  $H$ .

$\mu$  – функция, описывающая цветные маркеры  $C(t) \in C$  в позиции  $p \in P$ ,  $\mu(p): p \rightarrow \langle I, C(p) \rangle$ . Атрибут  $I$  используется для описания процессов, моделируемых нейроном:

- $\mu(p): p \rightarrow \langle x_i, C(p) \rangle$  – передачи входных данных  $x_i$  ( $i=1, 2, \dots, n$ ) для  $j$ -го нейрона;
- $\mu(p): p \rightarrow \langle w_i, C(p) \rangle$  – передачи весовых коэффициентов  $w_i$  ( $i=1, 2, \dots, n$ ) для  $j$ -го нейрона. Маркеры  $x_i$  и  $w_i$  имеют одинаковый цвет;
- $\mu(p): p \rightarrow \langle b_j, C(p) \rangle$  – передачи значения смещения  $b_j$  для  $j$ -го нейрона;

- $\mu(p): p \rightarrow \langle out_j, C(p) \rangle$  – передачи конечного результата с выхода  $j$ -го нейрона;
- $\mu(p): p \rightarrow \langle Bход_i, C(p) \rangle$  – передачи нейрону информации о входных данных  $x_i$ , соответствующих им весовых данных  $w_i$ , и значения смещения  $b_j$ .

$\tau$  – функция времени срабатывания, определяющая время выполнения операций в переходах  $t \in T$  (для каждого цвета).

$OC$  – функция вычисления, определяющая параметры, необходимые для выполнения операций сложения и умножения переходов  $t \in T$  в соответствии с имеющимся цветом  $C(t)$ :

- $OC_{j1}(t): T \rightarrow \langle x_i \times w_i, \tau, C(t) \rangle$  – функция, определяющая параметры для операции взвешивания входных данных:  $x_i \times w_i$ ;
- $OC_{j2}(t): T \rightarrow \langle sum_j, \tau, C(t) \rangle$  – функция, определяющая параметры для операции

сложения взвешенных данных  $j$ -го нейрона:  $sum_j = \sum_{i=1}^n x_i \times w_i$ ;

- $OC_{j3}(t): T \rightarrow \langle sum\_out_j, \tau, C(t) \rangle$  – функция, определяющая параметры для операции суммирования смещения и взвешенных данных  $j$ -го нейрона:  $sum\_out_j = sum_j + b_j$ .

$CT$  – функция связи  $CT(t): T \rightarrow \langle CT_i, \tau, C(t) \rangle$ . Определяет параметры, необходимые для срабатывания «связующих переходов»  $t \in T$  в соответствии с имеющимся цветом. Эти переходы моделируют поведение нейронов при приёме-передаче данных между собой.

$SIG$  – функция вычисления  $SIG(t): T \rightarrow \langle \varphi(sum\_out_j), \tau, C(t) \rangle$ . Определяет необходимые параметры для выполнения переходов  $t \in T$  сигмоидальной функции активации в соответствии с появлением цвета  $C(t)$ . Выходной результат выполнения операции вычисления сигмоидальной функции активации  $\langle out_j, C(p) \rangle$  рассчитывается с помощью атрибута  $\varphi: \varphi(sum\_out_j) = 1/(1 + \exp(-sum\_out_j))$ .

В  $CTPNNSIG$  существует функциональная зависимость между цветовым приоритетом включения переходов и цветовым приоритетом маркеров, размещаемых во входных позициях этих переходов./

**CTPNNSIG-модель искусственного нейрона.**  $CTPNNSIG$ -модель искусственного нейрона представлена на рис. 3. По аналогии с аппаратной моделью на моделируемый нейрон поступают четыре входных сигнала.

Для разрешения воздействия на моделируемый нейрон со стороны соседних нейронов используются ингибиторные дуги  $H(p_4, t_5)$ ,  $H(p_7, t_5)$ . При наличии маркера в позициях  $p_4$ ,  $p_7$  ингибиторная дуга запрещает нейрону получение данных от других нейронов до завершения текущих вычислений моделируемым нейроном. Когда указанные позиции пусты, моделируемый нейрон готов к дальнейшей связи с соседними нейронами.




Рис. 3. CTPNNSIG-модель искусственного нейрона

Поясним работу этой модели. В позицию  $p_1$  заносятся поступившие в нейрон входные данные  $\langle \text{Вход}_1, (\kappa, 1) \rangle$ ,  $\langle \text{Вход}_2, (3, 2) \rangle$ ,  $\langle \text{Вход}_3, (c, 3) \rangle$ ,  $\langle \text{Вход}_4, (y, 4) \rangle$ , помеченные цветными маркерами. При отсутствии маркеров в позициях  $p_4$  и  $p_7$ , срабатывает переход  $t_5$ , осуществляя передачу входных сигналов  $x_i$  в позицию  $p_2$ , соответствующих им весовых данных  $w_i$  в позицию  $p_3$  и значения смещения  $b_j$  моделируемого нейрона в позицию  $p_4$ . При этом маркер в позиции  $p_4$  запрещает переходу  $t_5$  принимать новые данные. Переход  $t_5$  выполняет операцию умножения  $w_i \times x_i$  — он последовательно обрабатывает маркеры, согласно их цветовому приоритету, и заносит полученные результаты в позицию  $p_5$ . Переход  $t_7$  выполняет операцию суммирования взвешенных входных сигналов, занося результат  $sum_j$  в позицию  $p_6$  с присвоенным ему максимальным цветовым приоритетом. Переход  $t_8$  производит суммирование маркеров позиций  $p_6$  и  $p_4$ , добавляя к  $sum_j$  смещение.

Полученный результат  $sum\_out_j$  заносится в позицию  $p_7$ . При этом ингибиторная дуга  $H(p_7, t_5)$ , запрещает переходу  $t_5$  получение данных. Переход  $t_9$  производит вычисление сигмоидальной функции активации  $\phi(sum\_out_j)$  и передает результат  $out_j$  в позицию  $p_8$ . При этом маркер покидает позицию  $p_7$ , снимая запрет для перехода  $t_5$ , и нейрон готов к дальнейшей работе.

**Формальное описание работы модели.** Формальное описание алгоритма работы модели и её динамическое поведение можно представить как множество всех состояний модели, которые могут быть достигнуты ею в определенный момент времени при срабатывании конечного числа переходов.

В исходном состоянии модели  $\text{Сост}_1$  позиция  $p_1$  содержит поступающие в моделируемый нейрон данные, помеченные цветными маркерами:  $\langle \text{Вход}_1, (\kappa, 1) \rangle$ ,  $\langle \text{Вход}_2, (3, 2) \rangle$ ,  $\langle \text{Вход}_3, (c, 3) \rangle$ ,  $\langle \text{Вход}_4, (y, 4) \rangle$ . Каждый цвет присваивает маркерам приоритет для организации последовательности событий на переходах  $t \in T$ .

Состояния модели описываются атрибутами  $MAP_i$ ,  $ПЕР_i$  и  $ИНГ_i$ .

Атрибут  $MAP_i$  показывает распределение маркеров в различных позициях текущего состояния модели в соответствии с функцией  $M_i$ .

Атрибут  $ПЕР_i$  описывает работу переходов в текущем состоянии и имеет три параметра:  $T_{сраб}$  – показывает сработанные переходы,  $T_{гот}$  – новые переходы готовые к срабатыванию и  $T_{мин}$  – отображает минимальное время срабатывания переходов, описываемых атрибутами  $T_{сраб}$  и  $T_{гот}$ . Целью параметра  $T_{мин}$  является оценка общего времени работы переходов до текущего состояния.

Атрибут  $ИНГ_i$  показывает распределение маркеров в ингибиторных местах и надписи на ингибиторных дугах, которые соответствуют текущему состоянию модели в соответствии с функцией  $H_i$ .

Формально состояния модели имеют следующее описание:

$$\begin{aligned} \text{Сост}_1: \quad MAP_1: \mu(p_1) &= \langle Bход_1, (\kappa, 1) \rangle, \langle Bход_2, (3, 2) \rangle, \langle Bход_3, (c, 3) \rangle, \langle Bход_4, (u, 4) \rangle \\ ПЕР_1: T_{мин}: t_5 &= \langle (\kappa, 1), (3, 2), (c, 3), (u, 4) \rangle \end{aligned}$$

$$\begin{aligned} \text{Сост}_2: \quad MAP_2: \mu(p_2) &= \langle x_1, (\kappa, 1) \rangle, \langle x_2, (3, 2) \rangle, \langle x_3, (c, 3) \rangle, \langle x_4, (u, 4) \rangle, \\ \mu(p_3) &= \langle w_1, (\kappa, 1) \rangle, \langle w_2, (3, 2) \rangle, \langle w_3, (c, 3) \rangle, \langle w_4, (u, 4) \rangle, \\ \mu(p_4) &= \langle b_j, (\kappa, 1) \rangle \\ ПЕР_2: T_{мин}: t_5 &= \langle (w_i \times x_i), \tau_1, ((\kappa, 1), (3, 2), (c, 3), (u, 4)) \rangle \\ ИНГ_2: H(p_4 \langle \kappa, 1 \rangle, t_5) & \end{aligned}$$

$$\begin{aligned} \text{Сост}_3: \quad MAP_3: \mu(p_2) &= \langle x_2, (3, 2) \rangle, \langle x_3, (c, 3) \rangle, \langle x_4, (u, 4) \rangle, \\ \mu(p_3) &= \langle w_2, (3, 2) \rangle, \langle w_3, (c, 3) \rangle, \langle w_4, (u, 4) \rangle, \mu(p_5) = \langle w_1 x_1, (\kappa, 1) \rangle, \\ \mu(p_4) &= \langle b_j, (\kappa, 1) \rangle \\ ПЕР_3: T_{мин}: t_5 &= \langle (w_i \times x_i), \tau_1, ((\kappa, 1), (3, 2), (c, 3), (u, 4)) \rangle \\ ИНГ_3: H(p_4 \langle \kappa, 1 \rangle, t_5) & \end{aligned}$$

$$\begin{aligned} \text{Сост}_4: \quad MAP_4: \mu(p_2) &= \langle x_3, (c, 3) \rangle, \langle x_4, (u, 4) \rangle, \\ \mu(p_3) &= \langle w_3, (c, 3) \rangle, \langle w_4, (u, 4) \rangle, \mu(p_5) = \langle w_1 x_1, (\kappa, 1) \rangle, \langle w_2 x_2, (3, 2) \rangle, \\ \mu(p_4) &= \langle b_j, (\kappa, 1) \rangle \\ ПЕР_4: T_{мин}: t_5 &= \langle (w_i \times x_i), \tau_1, ((\kappa, 1), (3, 2), (c, 3), (u, 4)) \rangle \\ ИНГ_4: H(p_4 \langle \kappa, 1 \rangle, t_5) & \end{aligned}$$

$$\begin{aligned} \text{Сост}_5: \quad MAP_5: \mu(p_2) &= \langle x_4, (u, 4) \rangle, \\ \mu(p_3) &= \langle w_4, (u, 4) \rangle, \mu(p_5) = \langle w_1 x_1, (\kappa, 1) \rangle, \langle w_2 x_2, (3, 2) \rangle, \langle w_3 x_3, (c, 3) \rangle, \\ \mu(p_4) &= \langle b_j, (\kappa, 1) \rangle \\ ПЕР_5: T_{мин}: t_5 &= \langle (w_i \times x_i), \tau_1, ((\kappa, 1), (3, 2), (c, 3), (u, 4)) \rangle \\ ИНГ_5: H(p_4 \langle \kappa, 1 \rangle, t_5) & \end{aligned}$$

- Сост<sub>6</sub>:**  $MAP_6 : \mu(p_5) = \langle w_1 x_1, (\kappa, 1) \rangle, \langle w_2 x_2, (3, 2) \rangle, \langle w_3 x_3, (c, 3) \rangle, \langle w_4 x_4, (u, 4) \rangle,$   
 $\mu(p_4) = \langle b_j, (\kappa, 1) \rangle$   
 $ПЕР_6 : T_{мин} : t_7 = \langle sum_j, \tau_2, ((\kappa, 1), (3, 2), (c, 3), (u, 4)) \rangle$   
 $ИНГ_6 : H(p_4 \langle \kappa, 1 \rangle, t_5)$
- Сост<sub>7</sub>:**  $MAP_7 : \mu(p_6) = \langle sum_j, (\kappa, 1) \rangle,$   
 $\mu(p_4) = \langle b_j, (\kappa, 1) \rangle$   
 $ПЕР_7 : T_{мин} : t_8 = \langle (sum_j + b_j), \tau_3, (\kappa, 1) \rangle$   
 $ИНГ_7 : H(p_4 \langle \kappa, 1 \rangle, t_5)$
- Сост<sub>8</sub>:**  $MAP_8 : \mu(p_7) = \langle (sum\_out_j), (\kappa, 1) \rangle$   
 $ПЕР_8 : T_{мин} : t_9 = \langle \phi(sum\_out_j), \tau_4, (\kappa, 1) \rangle$   
 $ИНГ_8 : H(p_7 \langle \kappa, 1 \rangle, t_5)$
- Сост<sub>9</sub>:**  $MAP_9 : \mu(p_6) = \langle out_j, (\kappa, 1) \rangle$

### Выводы

Достоинство предложенной модели состоит в использовании сигмоидальной функции активации, позволяющей исключить насыщение нейрона от больших сигналов, а также обеспечить возможность производить обучение нейронной сети в реальном масштабе времени при аппаратной реализации.

Модель в сравнении с известными является более адекватной процессам, реализуемым искусственными нейронами. В качестве входных и выходных сигналов могут быть не только бинарные сигналы, но и любые другие. Это позволяет достаточно полно обеспечивать свойства искусственного нейрона, необходимые при разработке конфигурации желаемой ИНС, с последующей аппаратной реализацией на ПЛИС.

Формальное описание функционирования модели представляет собой довольно простой метод для разработки и проверки алгоритмов обучения и диагностики, которые могут применяться на модели. Результаты анализа таких свойств сети, как условия выполнения переходов и время срабатывания переходов, проверяют реальную динамику функционирования модели.

### ЛИТЕРАТУРА

1. Himavathi S., Anitha D., Himavathi S. Feedforward Neural Network Implementation in FPGA Using Layer Multiplexing for Effective Resource Utilization. Muthuramalingam A. // IEEE Transactions on Neural Networks. 2007. Vol.18. No.3. P. 880-888.
2. Грибачев В.П. Элементная база аппаратных реализаций нейронных сетей // Компоненты и технологии. 2006. №8. С. 12-15.
3. Lee Y., Ko S.-B. FPGA Implementation of a Face Detector Using Neural Networks // IEEE CCECE/CCGEI. Ottawa. 2006. P. 1914-1917.
4. Sahin S., Becerikli Y., Yazici S. Neural Network Implementation in Hardware Using FPGAs // ICONIP 2006. Springer-Verlag Berlin Heidelberg, 2006. Part III. P. 1105-1112.
5. Питерсон Дж. Теория сетей Петри и моделирование систем. М.: Мир, 1984. 264 с.



6. Koriem S.M. CN-Nets for Modeling and Analyzing Neural Networks // Journal of King Saud University. Computer & Information Sciences. 2001. Vol.13. №1. P. 19-47.
7. Крюкова Д.Ю., Суконщиков А.А. Разработка системы моделирования сложных систем на базе нейронных сетей Петри // Актуальные проблемы управления и экономики: история и современность: мат. науч. конференции. Вологда: филиал СЗАГС, 2006. С. 144-148.
8. Хайкин С. Нейронные сети: полный курс, 2е издание. Пер. с англ. М.: Издательский дом «Вильямс», 2006. 1104 с.
9. Omondi A., Rajapakse J., Bajger M. FPGA Implementations of Neural Networks. Berlin: Springer, Germany, 2006. 360 p.

**Маршаков Даниил Витальевич** – аспирант Донского государственного технического университета, ассистент кафедры «Вычислительные системы и информационная безопасность» института энергетики и машиностроения Донского государственного технического университета

**Фатхи Денис Владимирович** – кандидат технических наук, старший научный сотрудник 1 научно-исследовательской лаборатории Ростовского военного института ракетных войск

**Marshakov Daniil Vital'evich** – Postgraduate Student of Don State Technical University, Technical Assistant of the Department “Computing Systems and Information Security”, Institute of Energy and Machine Building of Don State Technical University

**Fatkhi Denis Vladimirovich** – Candidate of Technical Science, Senior Research Worker of 1<sup>st</sup> Research Laboratory, Rostov Military Institute of Rocket Forces.

*Статья поступила в редакцию 20.03.2011, принята к опубликованию 20.08.2011*