

МЕТОД НЕЙРОННЫХ СЕТЕЙ ДЛЯ КЛИМАТИЧЕСКОГО ПРОГНОЗИРОВАНИЯ ВОДНОСТИ ЧЕРНОРЕЧЕНСКОГО ВОДОХРАНИЛИЩА

А.С. Лубков, Е.Н. Воскресенская

Институт природно-технических систем, РФ, г. Севастополь, ул. Ленина, 28

E-mail: andrey-ls2015@yandex.ru

Предложен новый метод прогнозирования сумм месячных осадков на станции Ай-Петри, в основе которого положена усовершенствованная модель с использованием искусственных нейронных сетей. В качестве входных параметров модели применялся набор глобальных океанических и метеорологических индексов за 1950–2020 гг., рассчитанных с применением реанализов NCEP/NCAR и HadISST. Поскольку зимой выпадает 40% суммы годовых осадков, для водности Чернореченского водохранилища этот сезон представляет наибольшую важность. Прогнозировать осадки на зимний сезон возможно в ноябре, и с более высоким качеством прогноза – в декабре. Среднее абсолютное отклонение прогнозов составило 28% и 23% соответственно. Кроме этого, в работе проверена и подтверждена возможность климатического прогноза атмосферного давления.

Ключевые слова: нейронные сети, моделирование, прогноз, осадки, давление, Ай-Петри, Чернореченское водохранилище, система океан–атмосфера

Поступила в редакцию: 08.06.2021. После доработки: 18.06.2021.

Введение. Чернореченское водохранилище является основным источником пресной воды г. Севастополь. Объем водохранилища составляет 64,2 млн м³, площадь водного зеркала – 6,04 км² [1]. Притоки водохранилища имеют паводковый режим с преобладанием стока в холодный период года (с ноября по апрель) [2].

По состоянию на 2019–2020 гг. среднегодовой баланс водных запасов водохранилища был отрицательным. Если в августе 2018 г. наполненность водохранилища составляла около 52 млн м³, то к январю 2021 г. объем воды в нем был близок к критическому, опускание ниже которого недопустимо ввиду защиты экосистемы водоема (рис. 1). Можно отметить несколько причин, которые повлияли на уровень водохранилища в эти годы. За период с 2014 по 2020 гг. прирост постоянно проживающего населения составил 126 тыс. человек (33% от численности населения 2014 г.), что в свою очередь могло привести к увеличению потребления воды городом. Однако более весомой причиной были засушливые гидрометеорологические условия в 2020 г. В этот год на горной метеостанции Ай-Петри, входящей в бассейн водосбора водохранилища, была зафиксирована рекордно низ-

кая годовая сумма осадков – всего 533 мм, что практически вдвое меньше среднееголетней нормы.




Рис. 1. Изменение водного зеркала Чернореченского водохранилища по данным спутниковых изображений Sentinel-2, для которых рассчитан индекс MNDWI [3]
Fig. 1. Changes in the lake-surface area of the Chernorechensky reservoir based on the data of Sentinel-2 satellite images, for which the MNDWI index is calculated [3]

Проблема дефицита воды порядка 30 млн м³ в засушливые годы была актуальна и ранее [4]. При этом учеными

г. Севастополя были предприняты попытки решить проблему путем забора паводковых вод р. Бельбек в резервное водохранилище, проектируемое в балке Темной (Камышловской) [4, 5], однако проект не был реализован. Близкое по принципу сооружение было реализовано лишь в марте 2021 г., когда силами Министерства обороны РФ создан и запущен в эксплуатацию Бельбекский водозабор. Планируется, что водозабор поможет наполнению Чернореченского водохранилища в паводковый период путем уменьшения потребления его воды городом. Номинальная мощность водозабора оценивается в 40 тыс. м³/сут., что составляет третья часть от потребления города (120 тыс. м³/сут. по [2]).

В связи с высокими темпами роста населения города и, следовательно, увеличением потребности в пресноводных ресурсах, а также климатическими угрозами, для благоприятного развития региона заблаговременное прогнозирование наполняемости Чернореченского водохранилища представляется одной из важнейших проблем.

Сезонные прогнозы (с заблаговременностью от месяца до года) на сегодня являются до сих пор до конца нерешенной проблемой, особенно на региональном масштабе. Требования, предъявляемые к качеству таких прогнозов невозможно достичь с помощью современных глобальных климатических моделей. Поэтому в данной работе мы рассмотрим возможность прогноза осадков и, дополнительно, давления с помощью модели на основе искусственных нейронных сетей (НС). Ранее авторы данной работы успешно применили этот метод для прогноза явлений Эль-Ниньо и Ла-Нинья с заблаговременностью до 9 месяцев [6, 7], для прогноза повторяемости интенсивных циклонов в Черноморском регионе с заблаговременностью до 6 месяцев [8] и для прогноза стока р. Дунай с заблаговременностью 3 месяца [9]. В качестве входных параметров в НС во всех случаях использовались только атмосферные индексы дальнедействующих связей системы океан – атмосфера.

Подготовка данных. Ранее в работах [6–9] моделировались ряды средне-

месячных климатических аномалий, нормированные на среднеквадратическое отклонение. При этом не проверялась возможность разложения ряда на ортогональные сигналы с последующим моделированием каждого сигнала по отдельности. Известно [10], что океанические параметры имеют несколько мод долгопериодной изменчивости, среди которых основными считаются Атлантическая мультideсятилетняя [11, 12] с периодом 60–70 лет, Тихоокеанская десятилетняя [13, 14] с периодом 20 лет и Эль-Ниньо – Южное колебание (ЭНЮК) [15] с 2–7-летним периодом чередования экстремальных фаз. Это основные моды глобальной климатической системы, характерные как океану, так и атмосфере. В то же время в атмосферных полях выделяется больше десятка мод [16, 17] с временным масштабом периода смены фаз от нескольких месяцев до нескольких лет.

Из работ [6, 9] известно, что количество входных индексов ограничено вычислительными мощностями. Для оптимальной работы НС ранее было рекомендовано использовать не более 25 входов. Разложение исходного ряда на несколько ортогональных рядов и последующее их отдельное моделирование подразумевает использование на входе в модель нескольких наборов индексов. Такой подход позволяет существенно увеличить количество входных индексов, а, следовательно, улучшить качество моделирования.

Принимая во внимание периоды основных климатических мод атмосферы и океана, моделируемые параметры раскладывались на два сигнала. Исходные ряды сглаживались 9-летним фильтром отдельно для каждого месяца. Примеры рядов температуры и атмосферного давления на уровне моря, приведенные на рис. 2, ярко демонстрируют наличие междесятилетней и десятилетней изменчивости. Сглаженный ряд и ряд разности исходных от сглаженных значений, далее будем называть *низкочастотной* и *высокочастотной* компонентой соответственно. Эти два новых ряда моделировались в текущей работе независимо друг от друга, а после моделирования – выполнялось их сложение.

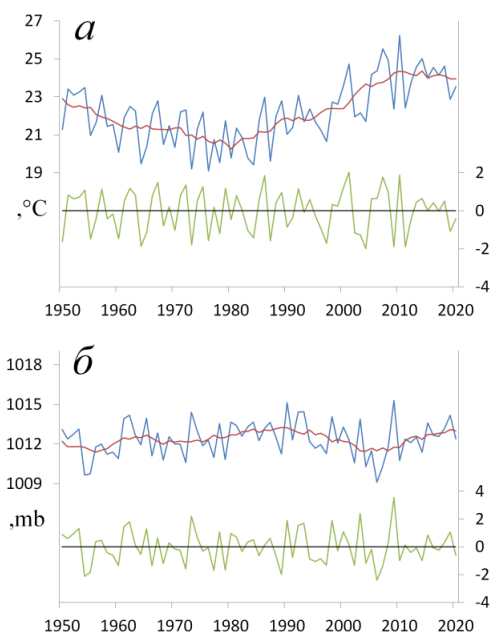


Рис. 2. Низкочастотная (красный – шкала слева), высокочастотная (зеленый – шкала справа) составляющие и исходный ряд (синий – шкала слева) температуры (а) и давления на уровне моря (б) в августе

Fig. 2. Low-frequency (red, scale on the left), high-frequency (green, scale on the right) components and the original rows (blue, scale on the left) of August temperature (a) and sea level pressure (б)

Для моделирования низкочастотной и высокочастотной составляющих прогнозируемой климатической характеристики использовалась однонаправленная гетероассоциативная многослойная НС, представленная персептроном с одним скрытым слоем [18, 19]. Таким образом, НС состоит из входного, скрытого и выходного слоев. При этом каждый нейрон текущего слоя связан с каждым нейроном предыдущего, а прямая связь между входным и выходным слоями и связь между нейронами одного слоя отсутствует. Выходной слой представлен лишь одним нейроном. Функция активации нейронов НС – сигмоидальная биполярная: $f(x) = \tanh(\beta x)$ [18].

Выбор входных параметров в НС для прогноза высокочастотной составляющей осуществлялся в несколько этапов. На первом этапе была изучена возможная статистическая взаимосвязь между моделируемыми метеорологическими характеристиками и глобальными ме-

теорологическими (геопотенциал, зональная и меридиональная составляющие скорости ветра на изобарическом уровне 500 мб) и океанологическими (температура поверхности океана – ТПО) полями. Статистическая связь оценивалась с помощью коэффициентов корреляции, которые рассчитывались в каждой узловой точке поля для каждого месяца по отдельности. Метеорологические и океанологические глобальные поля сравнивались с севастопольским регионом с временным сдвигом от 1 месяца до 2 лет. Итогом анализа глобальных полей было обобщение областей, в которых значимые коэффициенты корреляции с полями геопотенциальной высоты, зональной и меридиональной составляющих ветра на изобарической поверхности 500 мб, исходного ТПО и ТПО сглаженное 9-летним фильтром, наблюдались чаще. На рис. 2 полученные области выделены разными цветами (легенда приведена в подрисунковой надписи). Значения метеорологических и океанических параметров внутри области рассчитывались путем простого осреднения. Далее были рассчитаны атмосферные и океанические индексы. Для полей геопотенциальной высоты характерной чертой была синхронная корреляционная связь в соседствующих областях с противоположным знаком. Такие области объединялись в один индекс по одной из группы формул (1) и формуле (2).

$$\begin{aligned} X &= H_1 - H_2, \\ X &= H_1 - 2H_2 + H_3, \\ X &= H_1 - H_2 + H_3 - H_4, \end{aligned} \quad (1)$$

где H – осредненное значение геопотенциальной высоты в некоторой области, X – взвешенная разность нескольких областей;

$$Index_{i,m} = \frac{X_{i,m} - \bar{X}_m}{\sigma_m}, \quad (2)$$

где \bar{X} и σ – среднее и стандартное отклонение за период 1981–2010 гг., рассчитанные для каждого месяца отдельно, i и m – год и месяц. В случае, когда синхронная корреляция в ближайших областях не наблюдалась, индекс рассчитывался только по формуле (2).

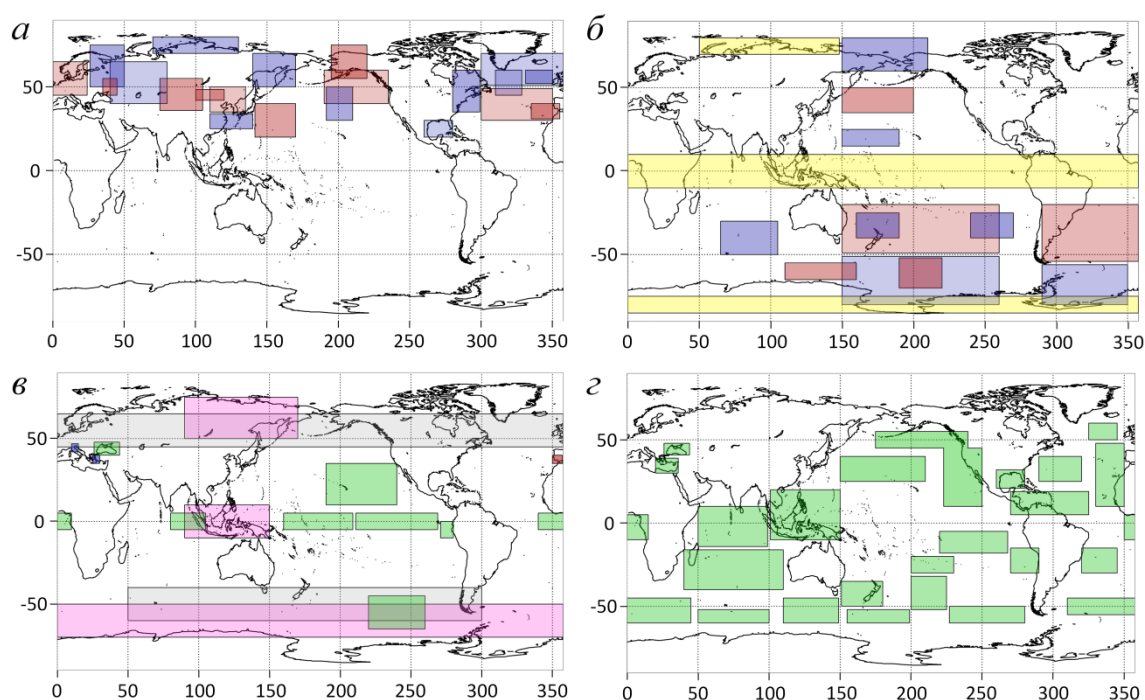


Рис. 3. Области, в которых рассчитывались индексы: красные, синие и желтые области на изображениях а, б и в – геопотенциальная высота на изобарической поверхности 500 мб; розовые и серые области на изображении в – зональная и меридиональная составляющие ветра соответственно, зеленые области на изображении в – ТПО, зеленые области на изображении г – ТПО, сглаженные девятилетним фильтром

Fig. 3. The areas, where the indices were calculated: red, blue and yellow areas in fig. 3-a, -b and -c is geopotential heights on the isobaric surface of 500 mb; the pink and gray areas in fig. 3-c is zonal and meridional components of the wind, respectively; the green areas in the fig. 3-c is SST, the green areas in the fig. 3-d is SST, used a 9-year filter

Большая часть индексов геопотенциальной высоты в Северном полушарии в целом соответствует месту локализации мод, выделенных в известной работе [16] (рис. 3, а). Остальные области расчетов индексов геопотенциала представлены на рис. 3, б. Дополнительно были рассчитаны индексы Средиземноморского и Западно-средиземноморского колебания (рис. 3, в – красная и две синие области) [20, 21].

На глобальных полях меридиональной и зональной компонент скорости ветра отмечены лишь несколько областей, в которых рассчитывались индексы по формуле (2). Эти области на рис. 3, в представлены розовым (зональная составляющая) и серым цветом (меридиональная). При этом особенностью расчета меридиональной компоненты скорости ветра было осреднение модуля его скорости в выделенной области. Такой индекс может служить индикатором ти-

па атмосферной циркуляции: положительные значения индекса соответствуют меридиональному типу, а отрицательные – зональному.

Выделенные области ТПО приведены на рис. 3, в (зеленый цвет). В их число вошли широко изученные экваториальные области, в которых наблюдаются явления Эль-Ниньо и Ла-Нинья [15], Атлантическая мода подобная ЭНЮК [22] и Индоокеанский диполь [23]. Эти глобальные экваториальные явления имеют доказанные климатические проявления в общей циркуляции атмосферы [24–26]. Во всех областях ТПО индексы рассчитывались так же, по формуле (2).

Для моделирования низкочастотной составляющей в качестве входных данных использовались только поля ТПО, сглаженные 9-летним фильтром для каждого месяца по отдельности. Выбор областей ТПО осуществлялся по аналогии с выбором областей для моделиро-

вания высокочастотной составляющей, при этом аномалии глобального поля ТПО сравнивались с аномалиями гидрометеопараметров сева­стопольского региона с временным сдвигом от 1 года до 10 лет.

В результате было выделено 25 регионов ТПО (рис. 3, з), в которых были рассчитаны индексы с использованием формулы (2).

Таким образом, для моделирования метеорологических характеристик Сева­стопольского региона было отобрано 54 индекса: 29 – для моделирования высокочастотной и 25 – для моделирования низкочастотной составляющих.

Описание модели. Моделирование осуществлялось для каждого месяца независимо друг от друга. Среднемесячные ряды значений моделируемого параметра и использованных входных индексов были разделены на обучающую, тестирующую и контрольную выборки. В текущей работе мы увеличили размер обучающей выборки с 28–30 лет, как в работах [6, 8], до 38 лет за период 1950–1987 гг., Тестовая выборка при этом сократилась и составила всего 19 лет – 1988–2006 гг. В качестве контрольной выборки рассматривался 14-летний период за 2007–2020 гг.

Обучение модели проводилось на основе алгоритма обратного распространения ошибки [19] с некоторыми поправками. Обычно максимум обучения определяется целевой функцией, рассчитываемой на каждом шаге обучающей выборки, и формулируется, как правило, в виде квадратичной суммы разностей между фактическими и ожидаемыми значениями выходного сигнала [18, 19]. Если достижение модельных расчетов и заведомо известных значений с некоторой требуемой точностью невозможно, максимум обучения определяется как глобальный минимум целевой функции [18]. В поставленной задаче установить требуемую точность модельных расчетов невозможно ввиду недостаточной изученности моделируемых параметров. При этом обучающая выборка состоит всего из 38 значений, что усложняет определение максимума обучения классическим методом. В этой связи для

определения максимума обучения применим метод, описанный в работе [9]. Суть обучения НС этим методом заключается в следующем. Корректировка весов нейронов НС осуществляется с помощью классической целевой функции, однако обучающая выборка повторяется многократно, при этом значения весов сохраняются. На каждой итерации повторения обучающей выборки рассчитываются коэффициенты корреляции с обучающей ($r_{обуч}$) и тестовой ($r_{тест}$) выборками. Максимум обучения НС должен удовлетворять двум условиям: осуществляется поиск итерации, на которой наблюдался глобальный максимум $r_{обуч}$, при этом, должно выполняться неравенство $|r_{тест} - r_{обуч}| < 0,15$. В случае, если второе условие не выполняется – за максимум обучения принимается ближайшая итерация, соответствующая обоим условиям. Однако недостатком этого метода является необходимость контрольной проверки моделируемых результатов. Это связано с тем, что в процессе поиска максимума обучения НС используется тестирующая выборка, следовательно, возникает необходимость использовать независимую (контрольную) выборку для объективной оценки возможностей модели.

Процесс адаптации модели включал в себя три стадии: предварительную обработку, моделирование и заключительную обработку результатов.

На этапе предварительной обработки повторно оценивалась статистическая связь между прогнозируемыми рядами данных и значениями входящих в модель НС индексов (геопотенциал, скорость ветра, ТПО) с временным сдвигом последних от одного месяца до двух лет опережения для высокочастотной составляющей и от одного года до десяти лет – для низкочастотной. На основе коэффициента корреляции осуществлялось ранжирование статистических связей с индексами с различным сдвигом. Поскольку рост количества входных параметров существенно влияет на скорость вычислений, в работе использовалось не более 22 входных индексов для моделирования высокочастотной составляющей

и не более 16 – для моделирования низкочастотной.

Ранее, в работе [9] было отмечено, что поведение НС не всегда может быть предсказуемо. На основе всех отобранных на предварительном этапе индексов модель показала неудовлетворительный результат. Это может быть связано с использованием индексов, не имеющих физической связи с моделируемым параметром и/или с тем, что входные индексы могут иметь тесную статистическую связь между собой. Поэтому моделирование проводилось с перебором всех возможных комбинаций индексов на входе, выбранных на предварительном этапе. В настоящей работе НС, имеющая определенный набор входных сигналов называется *конструкцией* модели. Максимально возможное количество конструкций НС можно представить как (3).

$$\text{Max} = \sum_{i=3}^N C_N^i, \quad (3)$$

где N – общее количество отобранных на предварительном этапе индексов, i – количество входных сигналов в НС ($i = 1, 2, \dots, N$).

Данные о конструкции НС (порядковый номер и время опережающего сдвига входных индексов), параметры этой НС в момент максимума обучения (количество нейронов скрытого слоя и итерация обучения) и корреляционные оценки на тестовой и обучающей выборке заносятся в лог-файл. Далее производилось ранжирование по коэффициенту корреляции конструкций НС с тестовой выборкой.

На заключительном этапе по результатам ранжирования отбирались 20 лучших конструкций НС, из которых рассчитывался ансамблевый ряд, качество которого оценивалось в сравнении с контрольной выборкой. Для такой оценки использовались следующие инструменты.

1. Корреляция Пирсона:

$$r = \frac{\text{cov}(x_i, y_i)}{\sigma_x \sigma_y}, \quad (4)$$

где σ_x и σ_y – среднеквадратические отклонения выборок x и y , которые представляют результат моделирования и наблюдаемые значения.

2. Отношение среднего квадратического отклонения модели относительно наблюдаемых значений (RMSE) к среднеквадратическому отклонению наблюдаемого ряда (СКО или σ)

$$\text{RMSE}/\sigma = \frac{\sqrt{\frac{\sum (x_i - y_i)^2}{n}}}{\sqrt{\frac{\sum (y_i - \bar{y})^2}{n-1}}} = \sqrt{\frac{(n-1) \cdot \sum (x_i - y_i)^2}{n \cdot \sum (y_i - \bar{y})^2}}, \quad (5)$$

где n – длина ряда контрольной выборки, x_i – модель, y_i – наблюдаемая величина, \bar{y} – среднее наблюдаемого ряда, i – год контрольной выборки.

3. Среднее абсолютное отклонение (E) использовалось только для оценки модельных осадков:

$$E = \frac{1}{n} \sum \frac{|x_i - y_i|}{y_i}, \quad (6)$$

где n , x_i , y_i и i по аналогии с (5).

Используемые данные. В работе использовались следующие массивы данных:

- среднемесячные ряды давления на уровне моря в координатах Чернореченского водохранилища были взяты из реанализа ERA5 за период 1950–2020 гг., пространственное разрешение которого $0,25^\circ \times 0,25^\circ$ (ряды составлялись из двух частей реанализа, учтены расхождения рядов, ряд 1950–1978 гг. проверен на ошибки на основе сравнения со станционными наблюдениями на метеостанции г. Симферополя, ряды которой доступны в базе международного обмена данными NOAA);

- данные о сумме месячных осадков на станции Ай-Петри были взяты из базы данных международного обмена NOAA за период 1950–2020 гг.;

- геопотенциальная высота и меридиональная, зональная составляющие ветра на изобарическом уровне 500 мб, используемые в качестве атмосферных входных индексов в НС, были взяты из реанализа NCEP/NCAR, пространственное разрешение которого составляет $2,5^\circ \times 2,5^\circ$, за период 1948–2020 гг.;

- реконструкционный массив данных о ТПО HadISST, имеющий разрешение $1^\circ \times 1^\circ$, использовался для поиска и расчета океанических индексов, входящих в НС за период 1940–2020 гг.

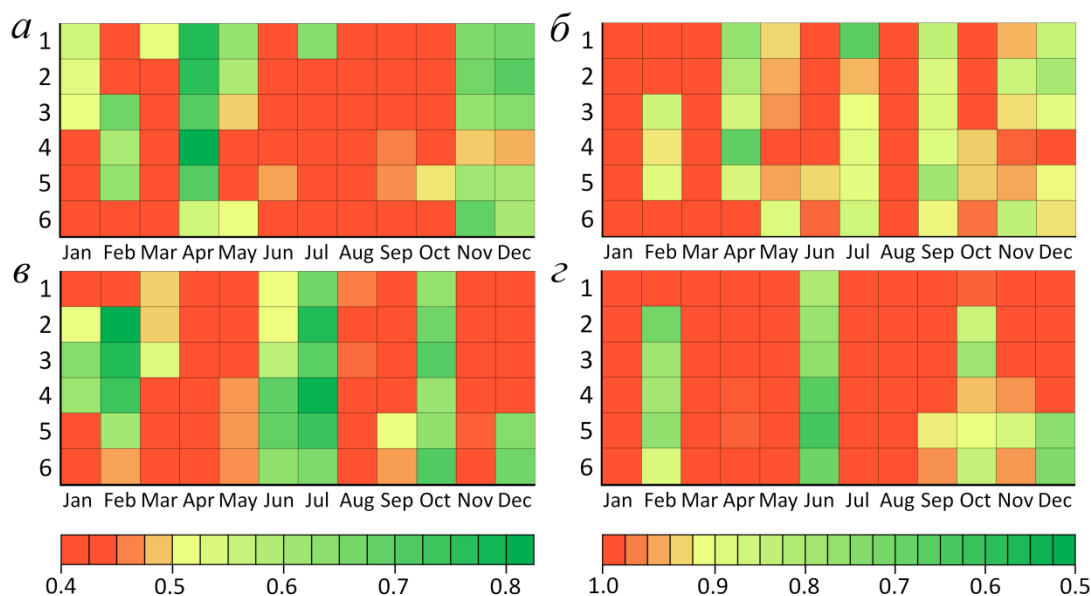


Рис. 4. Диаграммы коэффициента корреляции (*а, в*) и $RMSE/\sigma$ (*б, г*) рассчитанные для контрольного периода (2007–2020 гг.) в зависимости от месяца, для которого происходило моделирование, и заблаговременности прогноза для давления (*а, б*) и осадков на станции Ай-Петри (*в, г*)

Fig. 4. The diagrams of correlation (*a, c*) and $RMSE/\sigma$ (*b, d*) for various leads (months) and predicted months in the control period (2007–2020). sea level pressure (*a, b*) and precipitation on Ai-Petri (*c, d*)

Результаты. Осадки на станции Ай-Петри. Основной задачей текущей работы является создание прогностической модели для оценки пополнения Чернореченского водохранилища. Ключевую роль в наполнении Чернореченского водохранилища играют осадки, выпавшие в высокогорных районах бассейна его водосбора [2]. Поэтому в работе проверялась возможность прогнозировать осадки, наблюдаемые на станции Ай-Петри, расположенной на высоте 1180 м. На рис. 4 представлены оценки модельных расчетов с заблаговременностью прогноза от 1 до 6 месяцев (коэффициенты корреляции – рис. 4, *а, в*; $RMSE/\sigma$ – рис. 4, *б, г*). На весенние месяцы (март, апрель и май), а также на август и ноябрь прогноз осадков не представляется возможным: сравнение наблюдаемых величин и модельных расчетов показали незначимые корреляции ($r < 0,42$, при длине ряда – 14 значений и $\alpha = 0,01$) или/и среднее квадратическое отклонение модели больше среднее квадратическое отклонение от среднего ($RMSE/\sigma > 1$).

Пик выпадения атмосферных осадков в горах, в отличие от равнин, приходится на холодное полугодие. В среднем

40% годовых осадков выпадает зимой (декабрь, январь, февраль). И именно в этот период года формируется основной водоносный «потенциал» крымских водохранилищ. Прогноз этого сезона возможен как в ноябре, с заблаговременностью 4 месяца (заблаговременность считалась для последнего месяца сезона – февраля), так и в декабре, с заблаговременностью 2 месяца (рис. 5, *а*). Для прогноза заблаговременно за 4 месяца $r = 0,54$, $RMSE = 111$ мм, среднее отклонение модели равно 28% (рассчитывалось по формуле (6)). Для прогноза заблаговременно за 2 месяца $r = 0,65$, $RMSE = 101$ мм, среднее отклонение модели равно 23%.

Таким образом, прогноз с меньшей заблаговременностью несколько лучше воспроизводит осадки зимой. При этом сезон 2017–2018 гг. модель НС воспроизвела плохо: количество осадков было занижено на 69–75% (рис. 5).

Летом и в начале осени (июнь – октябрь) суммарно выпадает 30% годовых осадков. Интенсивные, но непродолжительные осадки в этот период и даже ливни кардинально повлиять на накопление воды в Чернореченском во-

дохранилище не могут. Прогнозировать количество осадков этого временного периода возможно в апреле, то есть заблаговременно за 6 месяцев (заблаговременность считалась для последнего месяца – октября). Отметим, что поскольку моделирование осадков в августе не представляется возможным, для этого месяца будем использовать прогноз лишь средней 9-летней составляю-

щей. Результаты модельных расчетов представлены на рис. 5, б. Модель воспроизвела количество осадков удовлетворительно: $r = 0,64$, $RMSE = 87$ мм, среднее отклонение модели $E = 22\%$. Наибольшие отклонения от наблюдаемых значений отмечались в 2016 г. (занижение на 44%) и 2017 г. (завышение на 74%).

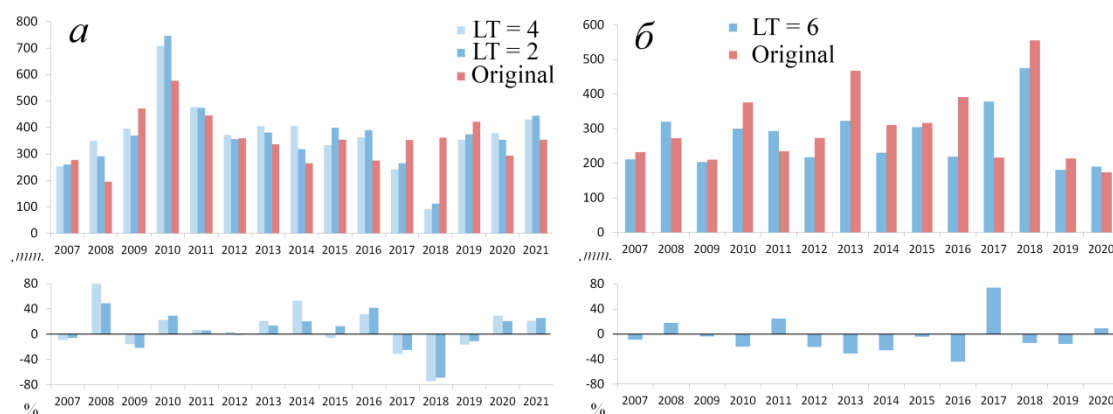


Рис. 5. Наблюдаемые осадки (original) и (а) – прогноз с заблаговременностью (LT) 2 и 4 месяца в зимний сезон (дек., янв., фев.), (б) – прогноз с заблаговременностью (LT) 6 месяцев в летний и осенний сезоны (июнь, июль, авг., сен., окт.);

внизу – отклонение модельных расчетов от наблюдений, %

Fig. 5. Observed precipitation (original) and forecast with lead time (LT) 2 and 4 months in winter season (DJF) (a); forecast with lead time (LT) 6 month in summer and autumn seasons (JJASO) (b); on the bottom is deviation of model calculations from observations, %

Результаты. Давление на уровне моря. Атмосферное давление на уровне моря может служить хорошим вспомогательным инструментом для прогнозирования осадков. Корреляционные оценки, полученные для каждого месяца, демонстрируют значимый уровень обратной статистической связи (при длине ряда – 70 значений и $\alpha = 0,001$ значимая корреляция равна 0,23) осадков и давления для января ($r = -0,67$), февраля ($r = -0,39$), марта ($r = -0,45$), июня ($r = -0,30$), сентября ($r = -0,53$), октября ($r = -0,30$), ноября ($r = -0,59$) и декабря ($r = -0,67$). При этом результаты оценки модельного прогноза давления на контрольной выборке, приведенные на рис. 4, а и 4, б, показали, что летом, в сентябре, октябре, а также марте прогноз аномалий среднемесячного давления практически невозможен. Для ноября и декабря прогнозирование среднемесячных значений дав-

ления допустимо на удовлетворительном уровне с заблаговременностью 1–3, 5 и 6 месяцев ($r = 0,6–0,69$; $RMSE/\sigma = 0,78–0,95$). В апреле модель показала высокие результаты с заблаговременностью прогноза от 1 до 5 месяцев ($r = 0,69–0,82$; $RMSE/\sigma = 0,66–0,86$). Заблаговременность прогноза удовлетворительного качества в январе не превышает 3 месяцев, в феврале – 5, в марте – 1, а в мае – 2. При этом в январе и марте $RMSE$ выше среднеквадратического отклонения.

Рассмотрим подробно воспроизводимость давления на контрольной выборке в месяцы, для которых показана наиболее высокая статистическая связь с осадками и отмечена возможность прогноза. На рис. 6 приведены несколько графиков модельных расчетов с различной заблаговременностью и наблюдаемое давление в ноябре, декабре, феврале и апреле.

Для ноября (рис. 6, а) обе модели с различной заблаговременностью прогноза имеют близкие коэффициенты корреляции (0,66–0,68) и $RMSE/\sigma$ (0,82–0,84), при этом наблюдаются неточности в воспроизведении давления. Декабри (рис. 6, б) воспроизводятся моделью НС в целом достаточно точно, кроме 2009 года. Прогноз с заблаговременностью 2 месяца ($r = 0,69$; $RMSE/\sigma = 0,78$) повторяет наблюдаемое среднемесячное давление точнее прогноза с заблаговременностью 6 месяцев ($r = 0,6$; $RMSE/\sigma =$

0,92). Феврالي модели с 3- и 5-месячной заблаговременностью (рис. 6, в) воспроизводят на одинаковом качественном уровне ($r = 0,66$ –0,61; $RMSE/\sigma = 0,85$ –0,88). В 2015–2017 гг. модельные расчеты заметно занижают давление. Наилучшим образом модель НС воспроизводит давление в апреле (рис. 6, г). При этом прогноз с заблаговременностью 4 месяца ($r = 0,83$; $RMSE/\sigma = 0,66$) несколько точнее прогноза с двухмесячной заблаговременностью ($r = 0,75$; $RMSE/\sigma = 0,79$).

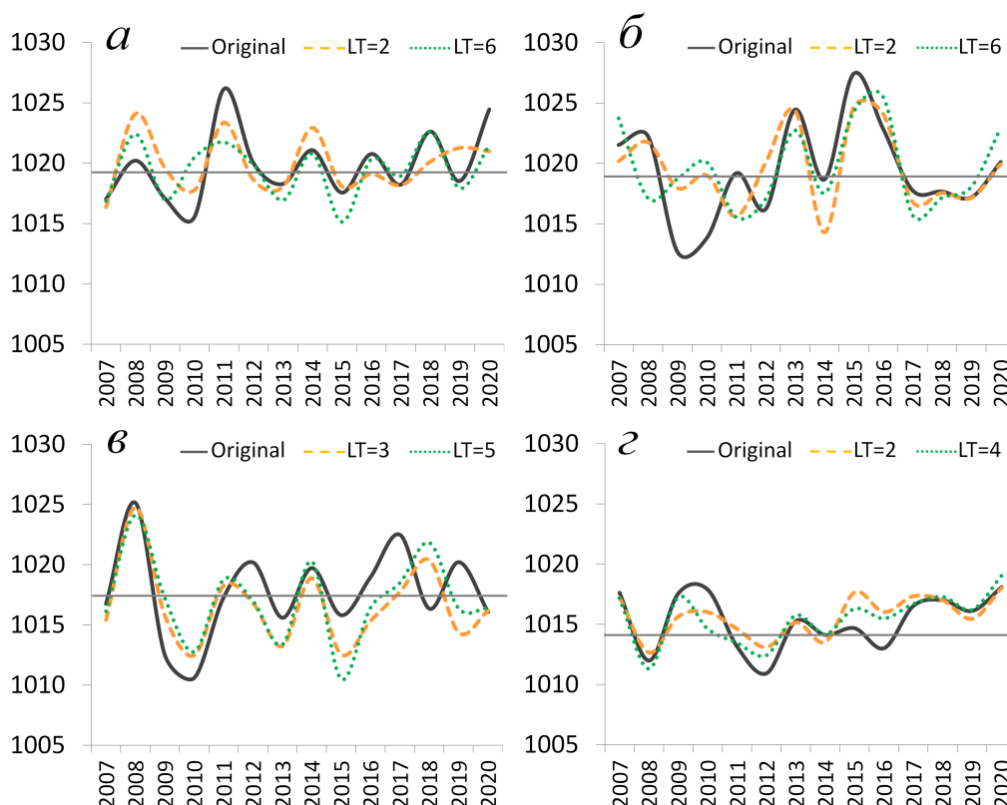


Рис. 6. Наблюдаемое давление, приведенное к уровню моря (original), среднемесячное значение (горизонтальная линия) и модельные расчеты с различной заблаговременностью (LT) на контрольном периоде для ноября (а), декабря (б), февраля (в) и апреля (г)

Fig. 6. Original sea level pressure, monthly average (horizontal line) and forecast's lead time (LT) in the control period for November (a), December (b), February (c) and April (d)

Выводы. В работе разработан новый подход ассимиляции данных и моделирования с помощью искусственных нейронных сетей, который позволил учесть низкочастотную и высокочастотную составляющие прогнозируемого параметра, а также увеличить вдвое количество предикторов, что в свою оче-

редь ведет к улучшению качества моделирования.

Модель способна прогнозировать осадки в районе станции Ай-Петри в зимний и летний сезоны, сентябрь и октябрь. В эти месяцы в среднем выпадает 70% годовой нормы осадков.

Прогноз осадков на зимний сезон возможно строить в ноябре, и с более

высоким качеством прогноза – в декабре. Среднее абсолютное отклонение на контрольной выборке составило 28% и 23% соответственно. При этом, прогноз осадков на этот сезон представляет наибольшую важность, поскольку в этот период года выпадает максимум осадков в горах, а следовательно и формируется основной объем водности Чернореченского водохранилища.

Прогноз осадков на летний период и сентябрь-октябрь возможно составлять в апреле (среднее абсолютное отклонение равно 22%). Однако этот период года имеет меньшее значение для прогноза наполняемости водохранилища, поскольку летние осадки, включая ливни, не оказывают на него существенного влияния.

Прогноз осадков весеннего сезона и ноября с помощью предложенной модели не представляется возможным.

Так же в работе показана высокая корреляционная связь осадков и давления на уровне моря в севастьяпольском регионе, особенно для ноября, декабря и января. Оценка воспроизводимости давления показала возможность его заблаговременного прогноза для ноября, декабря, января, февраля, апреля и мая. Давление может быть отличным вспомогательным инструментом для прогнозирования осадков.

Работа выполнена при финансовой поддержке Российского фонда фундаментальных исследований (проект № 20-45-920015) и государственного задания Института природно-технических систем по теме № 0012-2019-0007.

СПИСОК ЛИТЕРАТУРЫ

1. *Справочник водохранилищ СССР. Часть I. Водоохранилища объемом 10 млн м³ и более.* М.: Союзводпроект, 1988. 322 с.
2. *Трансформация стока воды и осадконакопление Чернореченского водохранилища* / М.Г. Гречушникова, А.Г. Косицкий, Д.Н. Айбулатов [и др.] // Вестник Московского университета. Серия 5. География. 2020. № 5 (1). С. 97–104.
3. *Xu H. Modification of Normalised Difference Water Index (NDWI) to Enhance Open Water Features in Remotely Sensed Imagery* // International Journal of Remote Sensing. 2006. Vol. 27 (14). P. 3025–3033. doi: 10.1080/01431160600589179
4. *Прусов А.В., Миньковская Р.Я., Овчаренко И.А.* Резерв пресноводных ресурсов Севастопольского региона // Экологическая безопасность прибрежной и шельфовой зон и комплексное использование ресурсов шельфа. 2009. № 19. С. 143–153.
5. *Водный баланс Севастопольского региона, водные ресурсы и их увеличение при строительстве водохранилища в балке Тёмной* / В.А. Иванов, А.В. Прусов, А.Н. Демидов [и др.] // Экологическая безопасность прибрежной и шельфовой зон и комплексное использование ресурсов шельфа. 2008. № 17. С. 48–59.
6. *Lubkov A.S., Voskresenskaya E.N., Marchukova O.V.* Forecasting El Niño/La Niña and Their Types Using Neural Networks // Russ. Meteorol. Hydrol. 2020. Vol. 45. P. 806–813. doi: 10.3103/S1068373920110084
7. *Lubkov A.S., Voskresenskaya E.N., Marchukova O.V.* Application of a neural network model to forecasting of El Niño and La Niña // IOP Conf. Ser.: Earth Environ. Sci. 2019. Vol. 386. P. 012040. doi: 10.1088/1755-1315/386/1/012040
8. *Intense Cyclones in the Black Sea Region: Change, Variability, Predictability and Manifestations in the Storm Activity* / V.N. Maslova, E.N. Voskresenskaya, A.S. Lubkov [et al.] // Sustainability. 2020. Vol. 12 (11). P. 4468. doi: 10.3390/su12114468
9. *Lubkov A.S., Voskresenskaya E.N., Kukushkin A.S.* Method for reconstructing the monthly mean water transparencies for the northwestern part of the Black Sea as an example // Atmos Ocean Opt. 2016. Vol. 29. P. 457–464. doi: 10.1134/S1024856016050092
10. *Enfield D., Mestas-Nunez A.M.* Multiscale variability in global SST and their relationships with tropospheric climate patterns // J. Climate. 1999. Vol. 12 (9). P. 2719–2733. doi: 10.1175/1520-0442(1999)012<2719:MVIGSS>2.0.CO;2

11. *Schlesinger M.E., Ramankutty N.* An oscillation in the global climate system of period 65–70 years // *Nature*. 1994. Vol. 367 (6465). P. 723–726. doi: 10.1038/367723a0
12. *Knight J.R., Folland C.K., Scaife A.A.* Climate impacts of the Atlantic Multidecadal Oscillation // *Geophys. Res. Lett.* 2006. Vol. 33. P. 17706. doi:10.1029/2006GL026242
13. *Zhang Y., Wallace J.M., Battisti D.S.* ENSO-like interdecadal variability: 1900–93 // *Journal of Climate*. 1997. Vol. 10. P. 1004–1020. doi: 10.1175/1520-0442(1997)010<1004:ELIV>2.0.CO;2
14. *A Pacific interdecadal climate oscillation with impacts on salmon production.* / N.J. Mantua, S.R. Hare, Y. Zhang [et al.] // *BAMS*. 1997. Vol. 78. P. 1069–1079. doi: 10.1175/1520-0477(1997)078<1069:A PICOW>2.0.CO;2
15. *Trenberth K.E., Caron J.M.* The Southern Oscillation Revisited: Sea Level Pressures, Surface Temperatures, and Precipitation // *J. Climate*. 2000. Vol. 13. P. 4358–4365. doi: 10.1175/1520-0442(2000)013<4358:TSORSL>2.0.CO;2
16. *Barnston G., Livezey R.E.* Classification, Seasonality and Persistence of Low-Frequency Atmospheric Circulation Patterns // *Monthly Weather Review*. 1987. Vol. 115 (6). P. 1083–1126. doi: 10.1175/1520-0493(1987)115<1083:CSAP OL>2.0.CO;2
17. *Wallace J.M., Gutzler D.S.* Teleconnections in the geopotential height field during the Northern Hemisphere winter // *Mon. Wea. Rev.* 1981. Vol. 109. P. 784–812. doi: 10.1175/1520-0493(1981)109<0784:TITGHF>2.0.CO;2
18. *Осовский С.* Нейронные сети для обработки информации. М.: Финансы и статистика, 2002. 344 с.
19. *Haykin S.* Neural networks, a comprehensive foundation, 1994. N.Y.: Macmillan College Publishing Company. 823 p.
20. *Upper-Level Mediterranean Oscillation index and seasonal variability of rainfall and temperature* / D. Redolat, R. Monjo, J.A. Lopez-Bustins [et al.] // *Theor. Appl. Clim.* 2019. Vol. 135. P. 1059–1077. doi: 10.1007/s00704-018-2424-6
21. *Martin-Vide J., Lopez-Bustins J.A.* The Western Mediterranean Oscillation and rainfall in the Iberian Peninsula // *International Journal of Climatology*. 2006. Vol. 26 (11). P. 1455–1475. doi: 10.1002/joc.1388
22. *On the spatiotemporal diversity of Atlantic Nino and associated rainfall variability over West Africa and South America* / I. Vallès-Casanova, S.-K. Lee, G.R. Foltz [et al.] // *Geophysical Research Letters*. 2020. Vol. 47 (8). P. e2020GL087108. doi: 10.1029/2020GL087108
23. *A dipole mode in the tropical Indian Ocean* / N. Saji, B. Goswami, P. Vinayachandran [et al.] // *Nature*. 1999. Vol. 401. P. 360–363. doi: 10.1038/43854
24. *McPhaden M.J., Zebiak S.E., Glantz M.H.* ENSO as an integrating concept in Earth science // *Science*. 2006. Vol. 314 (5806). P. 1740–1745. doi: 10.1126/science.1132588
25. *El Nino* Modoki and its possible teleconnection / K. Ashok, S. K. Behera, S. A. Rao [et al.] // *J. Geophys. Res.* 2007. Vol. 112. P. C11007. doi: 10.1029/2006JC003798
26. *Polonsky A.B., Basharin D.V.* How strong is the impact of the Indo-Ocean Dipole on the surface air temperature/sea level pressure anomalies in the Mediterranean region? // *Global and Planetary Change*. 2017. Vol. 151. P. 101–107. doi: 10.1016/j.gloplacha.2016.11.007

NEURAL NETWORK METHOD FOR CLIMATE FORECASTING WATER CONTENT OF THE CHERNORECHENSK RESERVOIR

A.S. Lubkov, E.N. Voskresenskaya

Institute of Natural and Technical Systems, RF, Sevastopol, Lenin St., 28

New method for monthly precipitation forecasting at the Ai-Petri region is proposed. This method includes a model based on artificial neural networks. A set of global oceanic and meteorological indices were used as the input parameters of the model. SST, geopotential and wind data sets from NCEP /

NCAR and HadISST re-analyses in 1950–2020 were used for indices calculation. Taking into account that the 40% of the annual precipitation obtain in winter, the main volume of water content of the Chernorechensk reservoir is formed in this season. It is shown that the best forecast of precipitation for the winter season can be made in November, and with a higher quality of the forecast – in December. The average absolute deviation was 28% and 23%, respectively. In addition, the work tested and confirmed the possibility of a climate forecast of atmospheric pressure.

Keywords: neural networks, modeling, forecast, precipitation, pressure, Ai-Petri, Chernorechensk reservoir, ocean-atmosphere system.

REFERENCES

1. Spravochnik vodohranilishh SSSR, Chast' I. Vodohranilishha ob'emom 10 mln m³ i bole (Reference book of reservoirs of the USSR. Part I. Reservoirs with a volume of 10 million m³ and more), Moscow, Sojuzvodproekt. 1988, 323 p.
2. Grechushnikova M.G., Kositsky A.G., Ajbulatov D.N., Shkolny D.I., Alekseeva A.A., and Karashova M.I. Transformacija stoka vody i osadkonakoplenie Chernorechenskogo vodohranilishha (Transformation of water runoff and sedimentation in the Chernorechensk reservoir). *Vestnik Moskovskogo universiteta. Seriya 5, Geografija*, 2020, Vol. 5, No. 1. pp. 97–104.
3. Xu H. Modification of Normalised Difference Water Index (NDWI) to Enhance Open Water Features in Remotely Sensed Imagery. *International Journal of Remote Sensing*, 2006, Vol. 27, No. 14, pp. 3025–3033. doi: 10.1080/01431160600589179
4. Prusov A.V., Min'kovskaja R.Ja., and Ovcharenko I.A. Rezerv presnovodnyh resursov Sevastopol'skogo regiona (The reserve of freshwater resources of the Sevastopol region). *Jekologicheskaja bezopasnost' pribrezhnoj i shel'fovoj zon i kompleksnoe ispol'zovanie resursov shel'fa*, 2009, Vol. 19. pp. 143–153.
5. Ivanov V.A., Prusov A.V., Demidov A.N., Min'kovskaja R.Ja., and Shestopalov V.M. Vodnyj balans Sevastopol'skogo regiona, vodnye resursy i ih uvelichenie pri stroitel'-stve vodohranilishha v balke Tjomonj (Water balance of the Sevastopol region, water resources and their increase during the construction of a reservoir in the Dark arroyo). *Jekologicheskaja bezopasnost' pribrezhnoj i shel'fovoj zon i kompleksnoe ispol'zovanie resursov shel'fa*, 2008, Vol. 17, pp. 48–59.
6. Lubkov A.S., Voskresenskaya E.N., and Marchukova O.V. Forecasting El Niño/La Niña and Their Types Using Neural Networks. *Russ. Meteorol. Hydrol.*, 2020, Vol. 45, pp. 806–813. doi: 10.3103/S1068373920110084
7. Lubkov A.S., Voskresenskaya E.N., and Marchukova O.V. Application of a neural network model to forecasting of El Niño and La Niña. *IOP Conf. Ser.: Earth Environ. Sci.*, 2019, Vol. 386, pp. 012040. doi: 10.1088/1755-1315/386/1/012040
8. Maslova V.N., Voskresenskaya E.N., Lubkov A.S., Yurovsky A.V., Zhuravskiy V.Y., and Evstigneev V.P. Intense Cyclones in the Black Sea Region: Change, Variability, Predictability and Manifestations in the Storm Activity. *Sustainability*, 2020, Vol. 12, No. 11, pp. 4468. doi: 10.3390/su12114468
9. Lubkov A.S., Voskresenskaya E.N., and Kukushkin A.S. Method for reconstructing the monthly mean water transparencies for the northwestern part of the Black Sea as an example. *Atmos. Ocean Opt.*, 2016, Vol. 29, pp. 457–464. doi: 10.1134/S1024856016050092
10. Enfield D. and Mestas-Nunez A.M. Multiscale variability in global SST and their relationships with tropospheric climate patterns. *J. Climate*, 1999, Vol. 12, No. 9, pp. 2719–2733. doi: 10.1175/1520-0442(1999)012<2719:MVGSS>2.0.CO;2
11. Schlesinger M.E. and Ramankutty N. An oscillation in the global climate system of period 65–70 years. *Nature*, 1994, Vol. 367, No. 6465, pp. 723–726. doi: 10.1038/367723a0
12. Knight J.R., Folland C.K., and Scaife A.A. Climate impacts of the Atlantic Multidecadal Oscillation. *Geophys. Res. Lett.*, 2006, Vol. 33, pp. 17706. doi:10.1029/2006GL026242
13. Zhang Y., Wallace J.M., and Battisti D.S. ENSO-like interdecadal variability: 1900–93. *Journal of Climate*, 1997, Vol. 10, pp. 1004–1020. doi: 10.1175/1520-0442(1997)010<1004:ELIV>2.0.CO;2
14. Mantua N.J., Hare S.R., Zhang Y., Wallace J.M., and Francis R.C. A Pacific interdecadal climate oscillation with impacts on salmon production. *BAMS*, 1997, Vol. 78, pp. 1069–1079. doi: 10.1175/1520-0477(1997)078<1069:APICOW>2.0.CO;2
15. Trenberth K.E. and Caron J.M. The Southern Oscillation Revisited: Sea Level Pressures, Surface Temperatures, and Precipitation. *J. Climate*, 2000, Vol. 13, pp. 4358–4365. doi: 10.1175/1520-0442(2000)013<4358:TSORSL>2.0.CO;2

16. Barnston G. and Livezey R.E. Classification, Seasonality and Persistence of Low-Frequency Atmospheric Circulation Patterns. *Monthly Weather Review.*, 1987, Vol. 115, No. 6, pp. 1083–1126. doi: 10.1175/1520-0493(1987)115<1083:CSAPOL>2.0.CO;2
17. Wallace J.M. and Gutzler D.S. Teleconnections in the geopotential height field during the Northern Hemisphere winter. *Mon. Wea. Rev.*, 1981, Vol. 109, pp. 784–812. doi: 10.1175/1520-0493(1981)109<0784:TITGHF>2.0.CO;2
18. Osovskij S. Nejronnye seti dlja obrabotki informacii (Neural networks for information processing), Moscow: Finansy i statistika, 2002, 344 p.
19. Haykin S. Neural networks, a comprehensive foundation, N.Y.: Macmillan College Publishing Company, 1994, 823 p.
20. Redolat D., Monjo R., Lopez-Bustins J.A., and Martin-Vide J. Upper-Level Mediterranean Oscillation index and seasonal variability of rainfall and temperature. *Theor. Appl. Clim.*, 2019, Vol. 135, pp. 1059–1077. doi: 10.1007/s00704-018-2424-6
21. Martin-Vide J. and Lopez-Bustins J.A. The Western Mediterranean Oscillation and rainfall in the Iberian Peninsula. *International Journal of Climatology*, 2006, Vol. 26, No. 11, pp. 1455–1475. doi: 10.1002/joc.1388
22. Vallès-Casanova I., Lee S.-K., Foltz G.R., and Pelegri J.L. On the spatiotemporal diversity of Atlantic Nino and associated rainfall variability over West Africa and South America. *Geophysical Research Letters*, 2020, Vol. 47, No. 8, pp. e2020GL087108. doi: 10.1029/2020GL087108
23. Saji N., Goswami B., Vinayachandran P., and Yamagata T. A dipole mode in the tropical Indian Ocean. *Nature*, 1999, Vol. 401, pp. 360–363. doi: 10.1038/43854
24. McPhaden M.J., Zebiak S.E. and Glantz M.H. ENSO as an integrating concept in Earth science. *Science*, 2006, Vol. 314, No. 5806, pp. 1740–1745. doi: 10.1126/science.1132588
25. Ashok K., Behera S.K., Rao S.A., Weng H., and Yamagata T. El Nino Modoki and its possible teleconnection. *J. Geophys. Res.*, 2007, Vol. 112, pp. C11007. doi: 10.1029/2006JC00379803798
26. Polonsky A.B. and Basharin D.V. How strong is the impact of the Indo-Ocean Dipole on the surface air temperature/sea level pressure anomalies in the Mediterranean region? *Global and Planetary Change*, 2017, Vol. 151, pp. 101–107. doi: 10.1016/j.gloplacha.2016.11.007