

ПРОБЛЕМЫ ВОДООБЕСПЕЧЕННОСТИ АРИДНЫХ РЕГИОНОВ

УДК 551.509.54, 556.5, 551.513.7

ПРОГНОЗ ВЫПАДЕНИЯ ОСАДКОВ В РАЙОНЕ АЙ-ПЕТРИ НА ОСНОВЕ МОДЕЛИ ИСКУССТВЕННОЙ НЕЙРОННОЙ СЕТИ¹

© 2022 г. А. С. Лубков^{a, b, *}, Е. Н. Воскресенская^a, О. Ю. Сухонос^a

^aИнститут природно-технических систем,
Севастополь, 299011 Россия

^bСевастопольский государственный университет,
Севастополь, 299053 Россия

*e-mail: andrey-ls2015@yandex.ru

Поступила в редакцию 14.12.2021 г.

После доработки 14.02.2022 г.

Принята к публикации 28.02.2022 г.

Предложен усовершенствованный метод прогнозирования месячных осадков в горном Крыму на основе модели искусственной нейронной сети. В качестве входных параметров модели использовался набор климатических индексов глобальной системы океан–атмосфера за 1948–2020 гг., которые рассчитывались на основе данных реанализа NCEP/NCAR и HadISST1. Верификация модели проведена для контрольного периода 2007–2020 гг. Показана возможность сезонного прогноза осадков с заблаговременностью до 6 мес. Обнаружено, что модель способна удовлетворительно прогнозировать общее количество осадков в зимние, летние и осенние (сентябрь и октябрь) месяцы. При этом прогноз осадков в зимний период в горном Крыму особенно ценен с точки зрения наполнения местных водохранилищ, поскольку именно в этот период года выпадает ~70% их годовой суммы. Показано, что прогнозировать осадки на зимний сезон возможно в октябре и со сравнительно более высоким качеством прогноза — в декабре. Мера мастерства прогноза составила 62 и 56% соответственно. В апреле можно прогнозировать летние осадки и осадки в сентябре–октябре (мера мастерства прогноза составляет 55%). Параллельно с осадками проверена и подтверждена возможность сезонного прогнозирования атмосферного давления.

Ключевые слова: искусственная нейронная сеть, долгосрочный прогноз, модель прогнозирования погоды, моделирование, Ай-Петри, Крым, система океан–атмосфера.

DOI: 10.31857/S0321059622040137

ВВЕДЕНИЕ

Территория Крымского п-ова характеризуется низкой обеспеченностью водными ресурсами. Средняя густота речной сети в регионе составляет 0.22 км/км². При этом в горной части она достигает 0.7, а в равнинной — 0.12 км/км² [2]. Ресурсы речного стока 50%-й обеспеченности для горной части полуострова составляют 0.86, а в равнинной части — 0.13 км³ [5]. В последнее 8 лет с 2014 г. отмечается рост населения на территории Крыма, особенно в прибрежных регионах, что приводит к

росту нагрузки на водные ресурсы полуострова. Соответственно, проблема дефицита пресной воды в настоящее время — одна из наиболее актуальных для Крыма. Объем пресной воды в водохранилищах меняется от года к году и существенно зависит от объема осадков, выпадающих в горном Крыму. Это иллюстрируют спутниковые снимки нескольких водохранилищ Крыма, приведенные на рис. 1. Питающие водохранилища воды имеют паводковый режим с преобладанием стока в холодное время года (с ноября по апрель) [1].

По состоянию на 2019–2020 гг. среднегодовой баланс запасов воды в водохранилищах Крыма был отрицательным, а к январю 2021 г. объем воды во многих был близок к критическому (рис. 1). Такая ситуация в течение отмеченных лет была вызвана несколькими причинами. Наиболее существенная из них состояла в том, что в течение 2020 г. гидрометеорологические условия в регионе характеризовались скудными осадками. Тогда

¹ Работа выполнена в рамках государственного задания Института природно-технических систем “Фундаментальные и прикладные исследования закономерностей и механизмов формирования региональных изменений природной среды и климата под влиянием глобальных процессов в системе океан–атмосфера и антропогенного воздействия” (государственная регистрация 121122300072-3) и стратегического проекта № 3 программы “Приоритет-2030” Севастопольского государственного университета (государственная регистрация 121121700314-3).

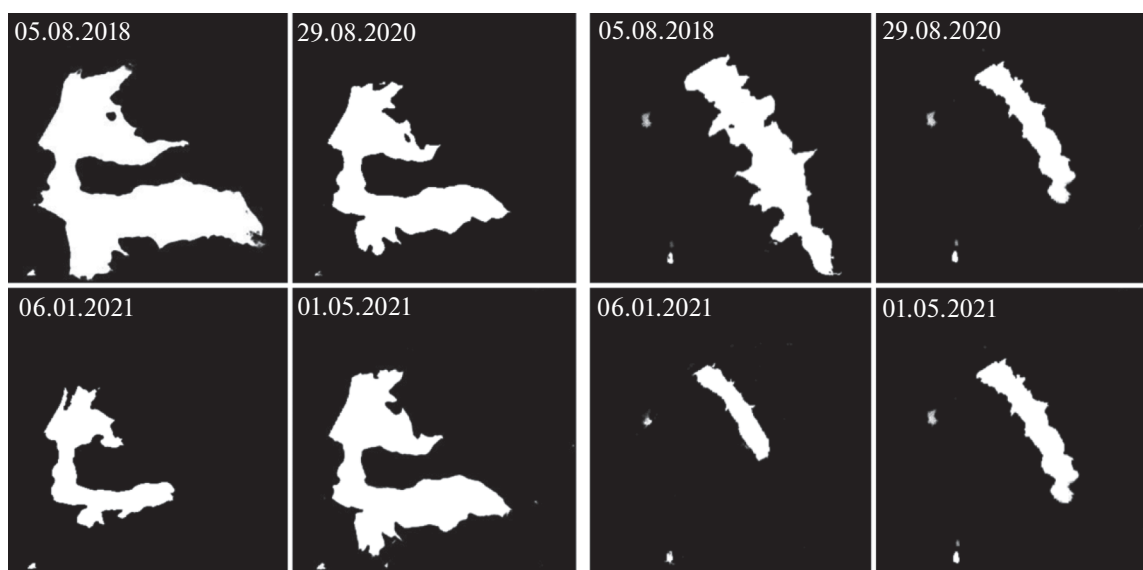


Рис. 1. Пример изменений площади водного зеркала двух водохранилищ Крыма по данным изображений спутника Sentinel-2, для которых рассчитан индекс MNDWI [34]; дата приведена в формате “день.месяц.год”.

на метеорологической станции на горе Ай-Петри было зафиксировано рекордно низкое годовое количество осадков — 533 мм, что соответствует лишь половине многолетней годовой нормы. Важно отметить, что проблема нехватки воды в Крыму в засушливые годы была известна и ранее [4].

В настоящее время решение проблемы сложившейся катастрофической ситуации в стратегически важном регионе было вынесено на правительственный уровень страны. При этом совершенно ясно, что своевременное прогнозирование осадков представляется одной из наиболее важных проблем для устойчивого развития региона.

К сожалению, сезонные прогнозы с заблаговременностью от месяца до года все еще остаются нерешенной проблемой, особенно на региональном масштабе. Требования, предъявляемые к качеству прогноза, не могут быть выполнены с использованием современных глобальных климатических моделей. Поэтому в данном исследовании рассмотрена возможность прогнозирования осадков в горном Крыму, а также дополнительно и приземного давления с использованием модели на основе метода нейронных сетей (НС).

На сегодня вопрос о возможности прогнозирования осадков методами, основанными на использовании различных НС, актуален и привлекает внимание исследователей разных стран. В последнее десятилетие появились работы, в которых предложены модели для такого прогнозирования в месячном и сезонном масштабе в отдельных регионах земного шара. В частности, некоторые авторы применяли разные НС для прогнозирования муссонных осадков в Индии

[29, 30] и Шри-Ланке [24], прогнозирования осадков в Австралии [9, 11, 22], Иордании [6], Китае [14] и Греции [23]. Обычно исследователями проводится сравнение различных методов нейросетевого моделирования. При этом однонаправленная гетероассоциативная НС с одним или несколькими скрытыми слоями (часто такую схему НС называют многослойным персептроном) показала конкурентные результаты [11, 14, 29, 30, 35].

Модели для прогнозирования осадков с использованием НС можно условно разделить на две группы по критериям входных параметров: использующие региональные метеорологические характеристики за некоторый предыдущий период (осадки, минимальная и максимальная температура, влажность, различные индексы осадков и температуры) и использующие глобальные климатические сигналы (Южное колебание Эль-Ниньо (ЭНЮК), Тихоокеанская декадная осцилляция (ТДО), Атлантическая мультideкадная осцилляция (АМО), Индоокеанский диполь (ИОД) и др.). При этом удовлетворительное и даже высокое качество моделирования было достигнуто как в первом случае, например в [6, 9, 29], так и во втором [11, 22, 29].

Ранее авторы настоящей статьи успешно применяли НС для прогнозирования явлений Эль-Ниньо и Ла-Нинья с заблаговременностью до 9 мес. [16, 17], частоты интенсивных циклонов в Черноморском регионе — с заблаговременностью до 6 мес. [20], а первоначально — для стока р. Дунай с заблаговременностью до 3 мес. [15]. При этом во всех этих случаях в качестве входных параметров в НС использовались только атмосферные ин-




Рис. 2. Низкочастотные (линия 1, левая шкала), высокочастотные (линия 2, правая шкала) компоненты и исходные ряды (линия 3, левая шкала) температуры воздуха (а) и давления на уровне моря (б) в августе.

дексы дальнедействующих связей в системе океан–атмосфера.

В настоящей работе уделено особое внимание выбору параметров, входящих в НС, и предложен подход к моделированию рядов метеорологических данных с их разделением на несколько компонент.

МАТЕРИАЛЫ И МЕТОДЫ

Используемые базы данных

В работе использованы следующие массивы данных:

среднемесячные ряды давления на уровне моря в Крыму взяты из реанализа ERA5 за период 1950–2020 гг., пространственное разрешение которого $0.25^\circ \times 0.25^\circ$ (ряды составлялись из двух частей реанализа, учтены расхождения рядов, ряд 1950–1978 гг. проверен на ошибки на основе сравнения со стационарными наблюдениями на метеостанции г. Симферополя, ряды которой доступны в базе международного обмена данными NOAA);

данные о сумме месячных осадков на станции Ай-Петри взяты из базы данных международного обмена NOAA за период 1950–2020 гг.;

геопотенциальная высота, меридиональная, зональная составляющие ветра на изобарическом уровне 500 мб, используемые в качестве атмосферных входных индексов в НС, взяты из реанализа NCEP/NCAR, пространственное разрешение которого составляет $2.5^\circ \times 2.5^\circ$, за период 1948–2020 гг.;

массив реконструированных данных о ТПО HadISST, имеющий разрешение $1^\circ \times 1^\circ$, использовался для поиска и расчета океанических индексов, входящих в НС за период 1940–2020 гг.

Подготовка данных

В ранних исследованиях авторов данной статьи [15–20] показано, что количество входных индексов ограничено вычислительными возможностями: для оптимальной работы модели рекомендовано использовать ≤ 25 . Разложение исходного ряда на несколько статистически несвязанных компонент и их последующее отдельное моделирование предполагают использование нескольких наборов индексов, подаваемых для моделирования каждой компоненты. Такой подход позволит значительно увеличить количество используемых индексов и, следовательно, улучшить качество моделирования.

Из [10] известно, что океанические параметры имеют несколько мод долгопериодной изменчивости, среди которых основными считаются АМО [13, 28] с типичным периодом 60–70 лет, ТДО [18, 36] с квази-двадцатилетним временным масштабом и межгодовые колебания САК, ЭНЮК и другие [31] с периодом чередования экстремальных фаз – 2–7 лет. Это основные режимы глобальной климатической системы, присутствующие как океану, так и атмосфере. При этом в атмосферных полях выделяется более десятка режимов с временным масштабом от нескольких месяцев до нескольких лет [8, 33].

С учетом типичных периодов основных климатических режимов атмосферы и океана моделируемые параметры разложены на две компоненты. Исходные ряды сглаживались 9-летним фильтром отдельно для каждого месяца. Примеры рядов температуры и атмосферного давления на уровне моря, приведенные на рис. 2, ярко демонстрируют наличие междесятилетней и десятилетней изменчивости. Сглаженный ряд и ряд разности исходных и сглаженных значений далее будем называть низкочастотной и высокочастотной компонентами соответственно. Эти два новых ряда моделировались в текущей работе неза-

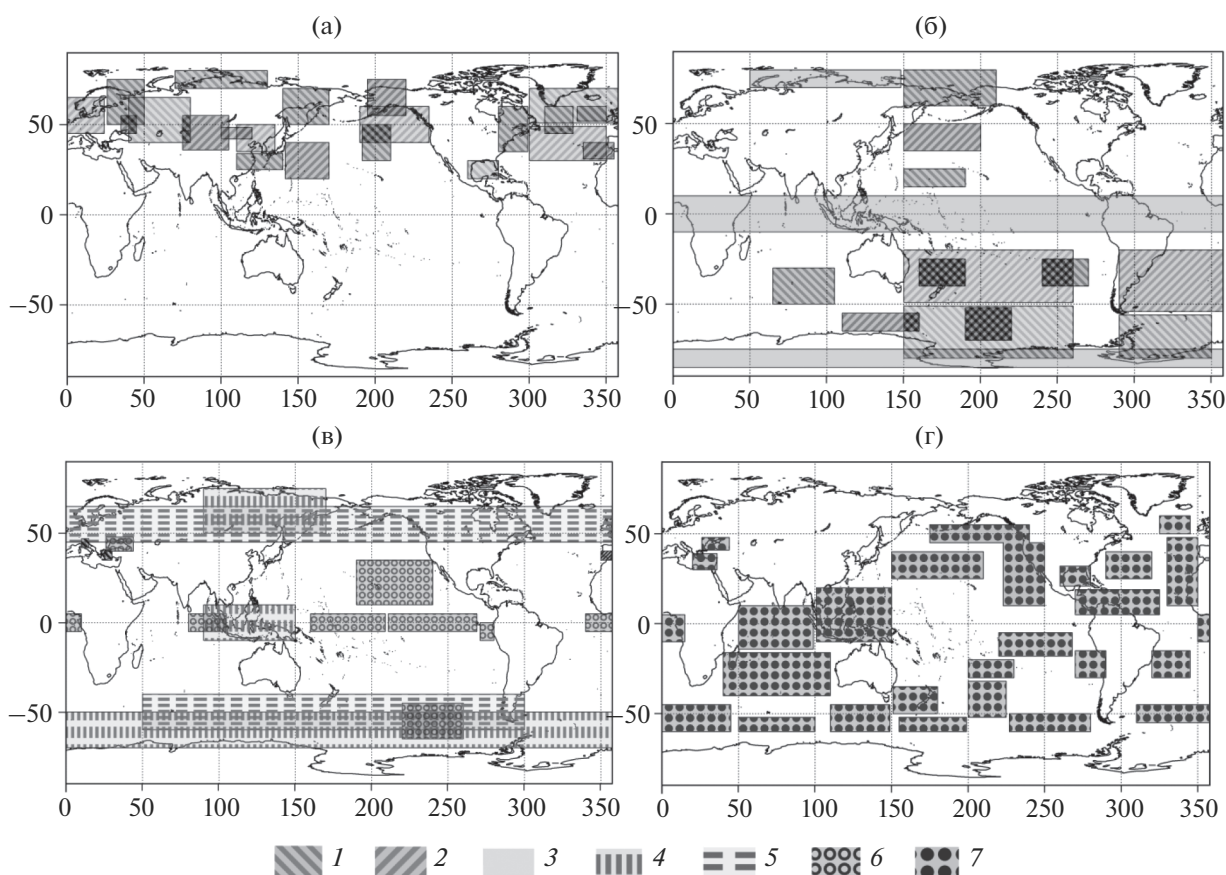


Рис. 3. Локализация пространственного расположения индексов. Области индексов геопотенциальной высоты на изобарической поверхности 500 мб отмечены штриховкой – 1, 2 и 3; меридиональной и зональной составляющих ветра – 4 и 5 соответственно, ТПО – 6 и сглаженные 9-летним средним скользящим фильтром ряды ТПО – 7.

висимо друг от друга, а после моделирования выполнялось их сложение.

Рассмотрим алгоритм выбора входных сигналов для модели НС. Для прогнозирования высокочастотной составляющей входные сигналы в НС выбирались в несколько этапов. На первом этапе была изучена возможная статистическая взаимосвязь между моделируемыми метеорологическими характеристиками и глобальными метеорологическими (геопотенциал, зональная и меридиональная составляющие скорости ветра на изобарическом уровне 500 мб) и океанологическими (температура поверхности океана (ТПО)) полями. Статистическая связь оценивалась с помощью коэффициентов корреляции, которые рассчитывались в каждой узловой точке поля для каждого месяца отдельно. Глобальные метеорологические и океанологические поля сравнивались с осадками на станции Ай-Петри и давлением на уровне моря, осредненным по Крымскому региону, с временным сдвигом от 1 мес. до 2 лет. Анализ глобальных полей привел к обобщению областей (рис. 3), в которых чаще наблюдались значительные коэффициенты корреляции (при

длине ряда 70, и $\alpha = 0.01$ коэффициент корреляции $r = 0.195$). В пределах этих областей выполнялось осреднение. В случае нескольких связанных областей индексы рассчитывались как сумма модулей корреляций всех таких областей. Использовались нормированные на стандартное отклонение аномалии.

Большая часть индексов геопотенциальной высоты в Северном полушарии в целом соответствует месту локализации мод, определенных Э.Г. Барнстоном и Р.Е. Ливези [8] (рис. 3а). Остальные области расчетов индексов геопотенциала представлены на рис. 3б. Кроме того, рассчитаны индексы Средне-Средиземноморского и Западно-Средиземноморского колебаний [19, 26] (рис. 3в).

На рис. 3в (штриховки “4” и “5”) представлены области расположения индексов, выделенных в глобальных полях меридиональной и зональной компонент скорости ветра. При этом особенно сильно расчет меридиональной компоненты скорости ветра было осреднение модуля его скорости в выделенной области. Такой индекс может служить индикатором типа атмосферной циркуляции:

положительные значения индекса соответствуют меридиональному типу, а отрицательные — зональному.

Штриховкой “6” на рис. 3в выделены области расположения индексов, полученных по аномалиям ТПО. В их число вошли известные аномалии: Эль-Ниньо — Южное колебание [31], Атлантическая мода, подобная ЭНЮК [32], и Индо-океанский диполь [27], имеющие глобальные климатические проявления [7, 21, 25, 32].

Для моделирования низкочастотной составляющей в качестве входных данных использовались только поля ТПО, сглаженные 9-летним фильтром для каждого месяца по отдельности. Выделенные области ТПО представлены на рис. 3г (штриховка “7”). Таким образом отобрано 54 индекса: 29 — для моделирования высокочастотной и 25 — для моделирования низкочастотной составляющих.

Описание модели

Для моделирования низкочастотной и высокочастотной составляющих прогнозируемых климатических характеристик использовался многослойный персептрон с одним скрытым слоем; функция активации нейронов НС — сигмоидальная биполярная [3, 12, 15].

Моделирование каждого месяца проводилось независимо. Среднемесячные ряды значений моделируемого параметра и использованных входных индексов были разделены на обучающую, тестирующую и контрольную выборки. В текущей работе увеличили размер обучающей выборки с 28–30 лет (как в работах [16, 17, 20]) до 38 лет за период 1950–1987 гг. Тестовая выборка при этом сократилась и составила всего 19 лет — 1988–2006 гг. В качестве контрольной выборки рассматривался 14-летний период за 2007–2020 гг.

Обучение модели проводилось на основе алгоритма обратного распространения ошибки [12] с некоторыми поправками. Обычно максимум обучения определяется целевой функцией, рассчитываемой на каждом шаге обучающей выборки, и формулируется, как правило, в виде квадратичной суммы разностей между фактическими и ожидаемыми значениями выходного сигнала [3, 12]. Если достижение модельных расчетов и заведомо известных значений с некоторой требуемой точностью невозможно, максимум обучения определяется как глобальный минимум целевой функции [3]. В поставленной задаче установить требуемую точность модельных расчетов невозможно ввиду недостаточной изученности моделируемых параметров. При этом обучающая выборка состоит всего из 38 значений, что усложняет определение максимума обучения классическим методом. В этой связи для определения максимума обуче-

ния применим метод, описанный в работе [15]. Суть обучения НС этим методом заключается в следующем. Корректировка весов нейронов НС осуществляется с помощью классической целевой функции, однако обучающая выборка повторяется многократно, при этом значения весов сохраняются. На каждой итерации повторения обучающей выборки рассчитываются коэффициенты корреляции с обучающей ($r_{\text{обуч}}$) и тестовой ($r_{\text{тест}}$) выборками. Максимум обучения НС должен удовлетворять двум условиям: осуществляется поиск итерации, на которой наблюдался глобальный максимум $r_{\text{обуч}}$, при этом должно выполняться неравенство $|r_{\text{тест}} - r_{\text{обуч}}| < 0.15$. В случае, если второе условие не выполняется, за максимум обучения принимается ближайшая итерация, соответствующая второму условию. Однако недостаток этого метода — необходимость контрольной проверки моделируемых результатов. Это связано с тем, что в процессе поиска максимума обучения НС используется тестирующая выборка и, следовательно, возникает необходимость использовать независимую (контрольную) выборку для объективной оценки возможностей модели.

Адаптация модели включала в себя несколько этапов. На этапе предварительной подготовки данных повторно оценивалась статистическая связь между прогнозируемыми рядами данных и значениями входящих в модель НС индексов (геопотенциал, скорость ветра, ТПО) с временным сдвигом последних от одного месяца до двух лет опережения для высокочастотной составляющей и от одного года до десяти лет — для низкочастотной. На основе коэффициента корреляции проводилось ранжирование статистических связей с индексами с различным сдвигом. Поскольку увеличение числа входных параметров существенно влияет на скорость вычисления, в исследовании для моделирования высокочастотной и низкочастотной составляющих использовано не более 22 и 16 входных индексов соответственно.

Ранее в работе [15] утверждалось, что поведение НС не всегда может быть предсказуемо. Поэтому моделирование проводилось с перебором всех возможных комбинаций индексов на входе, выбранных на предварительном этапе. В настоящей работе НС, имеющая определенный набор входных сигналов, называется конструкцией модели.

Для каждой конструкции НС проводилось обучение. Данные о конструкции НС в момент максимума обучения (количество нейронов скрытого слоя, итерация обучения, корреляционные оценки на тестовой и обучающей выборке) занесли в лог-файл. Далее проводилось ранжирование по коэффициенту корреляции конструкций НС с тестовой выборкой. По результатам

ранжирования отбирались 20 лучших конструкций НС и рассчитывался ансамбль как среднее арифметическое выбранных конструкций. Качество ансамбля оценивалось в сравнении с контрольной выборкой. Для такой оценки использовались следующие инструменты.

1. Корреляция Пирсона:

$$r = \frac{\text{cov}(x_i, y_i)}{\sigma_x \sigma_y}, \quad (1)$$

где σ_x и σ_y — среднеквадратические отклонения выборок x и y , которые представляют собой результат моделирования и наблюдаемые значения.

2. Отношение среднего квадратичного отклонения модели относительно наблюдаемых значений (RMSE) к среднеквадратическому отклонению наблюдаемого ряда (СКО или σ):

$$\text{RMSE}/\sigma = \frac{\sqrt{\frac{\sum (x_i - y_i)^2}{n}}}{\sqrt{\frac{\sum (y_i - \bar{y})^2}{n-1}}} = \sqrt{\frac{(n-1) \sum (x_i - y_i)^2}{n \sum (y_i - \bar{y})^2}}, \quad (2)$$

где n — длина ряда контрольной выборки, x_i — модель, y_i — наблюдаемая величина, \bar{y} — среднее наблюдаемого ряда, i — год контрольной выборки.

3. Мера мастерства прогноза:

$$S = \frac{E - E_0}{E_1 - E_0} \times 100\%,$$

где E — абсолютное отклонение модели, E_0 — абсолютное отклонение относительно среднего на контрольном периоде, E_1 — идеальная модель. Для идеальной модели справедливо $E_1 = 0$. Получим:

$$S = \frac{\sum_{i=1}^n |y_i - \bar{y}| - \sum_{i=1}^n |x_i - y_i|}{\sum_{i=1}^n |y_i - \bar{y}|} \times 100\%, \quad (3)$$

где n , x_i , y_i и i — по аналогии с (2).

РЕЗУЛЬТАТЫ

Осадки на станции Ай-Петри

Основная задача настоящей работы — создание прогностической модели для оценки будущей наполняемости отдельных водохранилищ Крыма. Осадки в высокогорных районах — основной фактор их наполнения [1]. Наиболее полные данные об осадках в горах Крыма имеются на станции Ай-Петри, расположенной на высоте 1180 м. На рис. 4 представлены оценки модельных расчетов с заблаговременностью прогноза от 1 до 6 мес. (коэффициенты корреляции на рис. 4а, RMSE/ σ на рис. 4б). Для весенних месяцев (март,

апрель и май), а также для августа и ноября прогнозировать осадки оказалось невозможным: сравнение наблюдаемых и рассчитанных с использованием модели значений показало незначимые корреляции ($r < 0.42$ с длиной ряда 14 значений и $\alpha = 0.01$) и/или RMSE модели превышает стандартное отклонение ($\text{RMSE}/\sigma > 1$).

В отличие от равнин, в горах пик атмосферных осадков приходится на холодную половину года. В среднем 40% годовых осадков выпадает зимой (декабрь, январь, февраль). Именно в этот период формируется основной водоносный потенциал крымских водохранилищ. Прогноз этого сезона возможен как в ноябре с заблаговременностью 4 мес. (заблаговременность считалась для последнего месяца сезона — февраля), так и в декабре с заблаговременностью 2 мес. (рис. 5а). Для прогноза с заблаговременностью 4 мес. $r = 0.54$, RMSE = 111 мм, мера мастерства модели равна 56%. Для прогноза с заблаговременностью 2 мес. $r = 0.65$, RMSE = 101 мм, мастерство модели $S = 62\%$.

Таким образом, прогноз с меньшей заблаговременностью несколько лучше воспроизводит осадки зимой. При этом сезон 2017—2018 гг. модель НС воспроизвела плохо: количество осадков занижено на 69—75% (рис. 5). Летом и в начале осени (июнь—октябрь) суммарно выпадает 30% годовых осадков. Интенсивные, но непродолжительные осадки и даже ливни в этот период не могут кардинально повлиять на накопление воды в водохранилищах Крыма. Прогнозировать количество осадков для этого временного периода возможно в апреле, т. е. с заблаговременностью 6 мес. (заблаговременность считалась для последнего месяца — октября). Поскольку моделирование осадков в августе не представляется возможным, для этого месяца будем использовать прогноз лишь средней 9-летней составляющей. Результаты модельных расчетов представлены на рис. 5б. Модель воспроизвела количество осадков удовлетворительно: $r = 0.64$, RMSE = 87 мм, мастерство модели $S = 55\%$. Наибольшие отклонения от наблюдаемых значений отмечались в 2016 г. (занижение на 44%) и 2017 г. (завышение на 74%).

Давление на уровне моря

Прогноз атмосферного давления на уровне моря может служить хорошим вспомогательным инструментом для интерпретации прогнозов осадков при условии наличия статистической связи. Анализ статистических связей, выполненный отдельно для каждого месяца, показал наличие значимых коэффициентов корреляции (длина ряда — 70 значений, $\alpha = 0.001$, $r_{\text{крит}} = 0.23$) в январе ($r = -0.67$), феврале ($r = -0.39$), марте ($r = -0.45$), июне ($r = -0.30$), сентябре ($r = -0.53$),

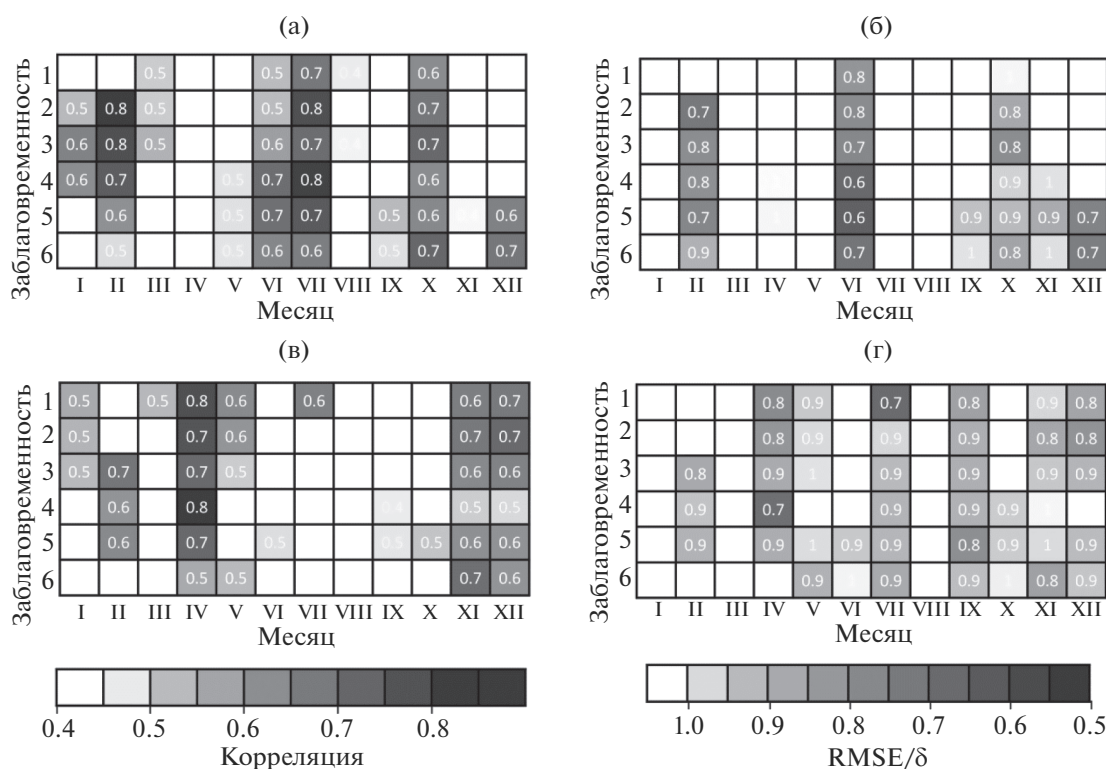


Рис. 4. Диаграммы коэффициента корреляции (а, в) и $RMSE/\sigma$ (б, г) рассчитанные для контрольного периода (2007–2020 гг.) в зависимости от месяца, для которого происходило моделирование, и заблаговременности прогноза для осадков на станции Ай-Петри (а, б) и давления (в, г).

октябре ($r = -0.30$), ноябре ($r = -0.59$) и декабре ($r = -0.67$).

Результаты оценки модельного прогноза давления на контрольной выборке, приведенные на рис. 4в и 4г, показали, что летом, в сентябре, октябре, а также в марте прогноз аномалий среднемесячного давления практически невозможен. Для ноября и декабря прогнозирование среднемесячных значений давления допустимо на удовлетворительном уровне с заблаговременностью 1–3, 5 и 6 мес. ($r = 0.6$ – 0.69 , $RMSE/\sigma = 0.78$ – 0.95). В апреле модель показала хорошие результаты с заблаговременностью прогноза от 1 до 5 мес. ($r = 0.69$ – 0.82 , $RMSE/\sigma = 0.66$ – 0.86). Заблаговременность прогноза удовлетворительного качества в январе не превышает ≤ 3 мес., в феврале – 5, в марте – 1, а в мае – 2 мес. При этом в январе и марте $RMSE$ выше среднеквадратического отклонения.

Рассмотрим подробно воспроизводимость давления на контрольной выборке в месяцы, для которых показана наиболее высокая статистическая связь с осадками и отмечена возможность прогноза. На рис. 6 приведено несколько графиков модельных расчетов с различной заблаговременностью и наблюдаемое давление в ноябре, декабре, феврале и апреле.

Для ноября (рис. 6а) обе модели с различной заблаговременностью прогноза имеют близкие коэффициенты корреляции (0.66 – 0.68) и $RMSE/\sigma$ (0.82 – 0.84), при этом наблюдаются неточности в воспроизведении давления. Воспроизведение декабрьского давления моделью НС (рис. 6б) в целом достаточное, кроме 2009 г. Прогноз с заблаговременностью 2 мес. ($r = 0.69$, $RMSE/\sigma = 0.78$) повторяет наблюдаемое среднемесячное давление точнее прогноза с заблаговременностью 6 мес. ($r = 0.6$, $RMSE/\sigma = 0.92$). Модели с 3- и 5-месячной заблаговременностью (рис. 6в) воспроизводят февральские значения на одинаковом качественном уровне ($r = 0.66$ – 0.61 , $RMSE/\sigma = 0.85$ – 0.88). Для 2015–2017 гг. модельные расчеты заметно занижают давление. Наилучшим образом модель НС воспроизводит давление в апреле (рис. 6г). При этом прогноз с заблаговременностью 4 мес. ($r = 0.83$, $RMSE/\sigma = 0.66$) несколько точнее прогноза с заблаговременностью 2 мес. ($r = 0.75$, $RMSE/\sigma = 0.79$).

ВЫВОДЫ

Предложенный в работе подход к ассимиляции данных позволил удвоить количество входных предикторов и, следовательно, увеличить потенциал предсказуемости модели НС. Проверка

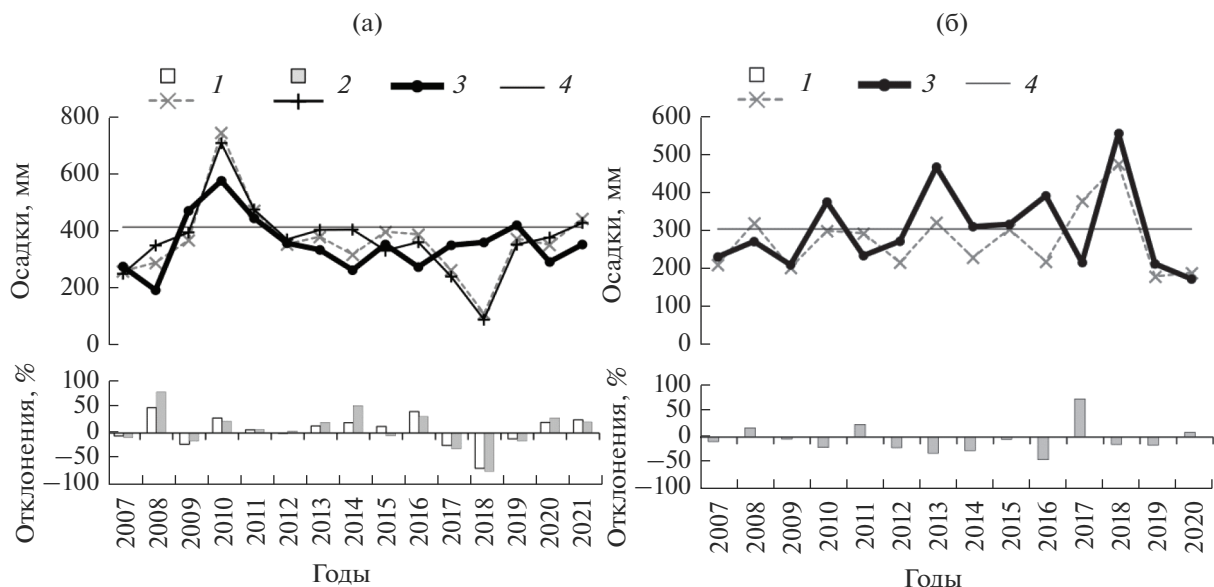


Рис. 5. Модельный прогноз на контрольной выборке: а – с заблаговременностью 2 (1) и 4 мес. (2) в зимний сезон (дек., янв., фев.); б – с заблаговременностью 6 мес. (1) в летний и осенний сезоны (июнь, июль, август, сентябрь, октябрь), наблюдаемые осадки (3) и средние осадки в соответствующие сезоны, рассчитанные для периода 1950–2020 гг. (4); диаграмма снизу – отклонение модельных расчетов от наблюдений, %.

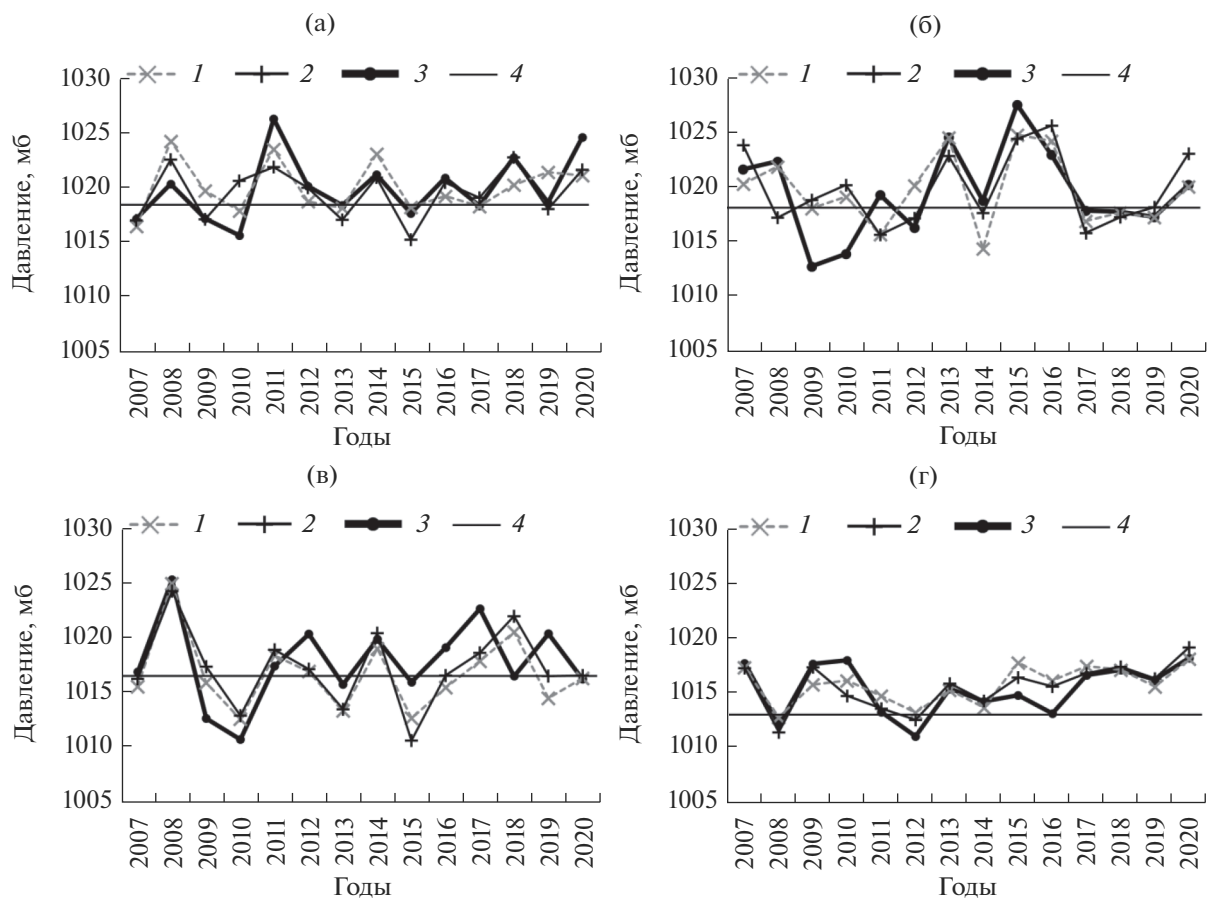


Рис. 6. Модельные расчеты давления на уровне моря в контрольный период для ноября (а) с заблаговременностью прогноза 2 (1) и 6 мес. (2), декабря (б) с заблаговременностью прогноза 2 (1) и 6 мес. (2), февраля (в) с заблаговременностью прогноза 3 (1) и 5 мес. (2), для апреля (г) с заблаговременностью прогноза 2 (1) и 4 мес. (2), наблюдаемые значения (3) и среднее давление в соответствующие месяцы, рассчитанные для периода 1950–2020 гг. (4).

качества моделирования показала, что прогнозирование осадков в районе станции Ай-Петри в зимние и летние месяцы, сентябре и октябре представляется возможным с заблаговременностью 2–6 мес. В эти месяцы в среднем выпадает ~70% годовой нормы осадков.

Для зимних осадков имеется потенциал предсказуемости в октябре, а сравнительно более точный прогноз на зимний сезон можно получить в декабре. Мастерство модели на контрольной выборке составило 56 и 62% соответственно. При этом прогноз осадков на зимний сезон имеет большое значение, так как в этот период максимальное количество осадков выпадает в горах, что обуславливает формирование водности базовых крымских водохранилищ.

Прогноз летних и осенних (июнь–октябрь) осадков можно составлять в апреле (Мастерство модели – 55%). Однако этот период менее важен для прогнозирования наполняемости водохранилищ Крыма, поскольку летние осадки, в том числе сильные дожди, существенного влияния на нее не оказывают.

Анализ воспроизводимости моделью давления на уровне моря показал возможность заблаговременного прогнозирования для ноября, декабря, января, февраля, апреля и мая. При этом давление может быть хорошим вспомогательным инструментом для интерпретации прогноза осадков.

Полученные результаты могут быть использованы для ранней оценки водоснабжения в большинстве регионов Крыма.

СПИСОК ЛИТЕРАТУРЫ

1. Гречушикова М.Г., Косицкий А.Г., Айбулатов Д.Н., Школьный Д.И., Алексеева А.А., Карашова М.И. Трансформация стока воды и осадконакопление Чернореченского водохранилища // Вест. Московского уни-та. Сер. 5, География. 2020. № 1. С. 97–104.
2. Олиферов А. Н. Тимченко З. В. Реки и Озера Крыма. Симферополь: Доля, 2005. 216 с.
3. Осовский С. Нейронные сети для обработки информации. М.: Финансы и статистика, 2002. 344 с.
4. Прусов А.В., Миньковская Р.Я., Овчаренко И.А. Резерв пресноводных ресурсов Севастопольского региона // Экологическая безопасность прибрежной и шельфовой зон и комплексное использование ресурсов шельфа. 2009. № 19. С. 143–153.
5. Справочник по водным ресурсам / Под ред. Б.И. Стрельца. Киев: Урожай, 1987. 304 с.
6. Aksoy H., Dahamsheh A. Artificial neural network models for forecasting monthly precipitation in Jordan // Stoch. Environ. Res. Risk Assess. 2009. V. 23. P. 917–931.
7. Ashok K., Behera S.K., Rao S.A., Weng H., Yamagata T. El Nino Modoki and its possible teleconnection // J. Geophys. Res. 2007. V. 112. P. 11007.
8. Barnston G., Livezey R.E. Classification, Seasonality and Persistence of Low-Frequency Atmospheric Circulation Patterns // Monthly Weather Rev. 1987. V. 115. № 6. P. 1083–1126.
9. Deo R.C., Şahin M. Application of the artificial neural network model for prediction of monthly standardized precipitation and evapotranspiration index using hydrometeorological parameters and climate indices in eastern Australia // Atmos. Res. 2015. V. 161–162. C. 65–81.
10. Enfield D., Mestas-Nunez A.M. Multiscale variability in global SST and their relationships with tropospheric climate patterns // J. Climate. 1999. V. 12 № 9. P. 2719–2733.
11. Haidar A., Verma B. Monthly Rainfall Forecasting Using One-Dimensional Deep Convolutional Neural Network // IEEE Access. 2018. V. 6. P. 69053–69063.
12. Haykin S. Neural networks, a comprehensive foundation. N. Y.: Macmillan College Publ. Company, 1994. 823 p.
13. Knight J.R., Folland C.K., Scaife A.A. Climate impacts of the Atlantic Multidecadal Oscillation // Geophys. Res. Lett. 2006. V. 33. P. 17706.
14. Lu W., Chu H., Zhang Z. Application of generalized regression neural network and support vector regression for monthly rainfall forecasting in western Jilin Province, China // J. of Water Supply: Res. and Technol.-Aqua. 2014. V. 64. № 1. P. 95–104.
15. Lubkov A.S., Voskresenskaya E.N., Kukushkin A.S. Method for reconstructing the monthly mean water transparencies for the northwestern part of the Black Sea as an example // Atmos. Ocean Opt. 2016. V. 29. P. 457–464.
16. Lubkov A.S., Voskresenskaya E.N., Marchukova O.V. Application of a neural network model to forecasting of El Niño and La Niña // IOP Conf. Ser.: Earth Environ. Sci. 2019. V. 386. P. 012040.
17. Lubkov A.S., Voskresenskaya E.N., Marchukova O.V. Forecasting El Niño/La Niña and Their Types Using Neural Networks // Russ. Meteorol. Hydrol. 2020. V. 45. P. 806–813.
18. Mantua N.J., Hare S.R., Zhang Y., Wallace J.M., Francis R.C. A Pacific interdecadal climate oscillation with impacts on salmon production // BAMS. 1997. V. 78. P. 1069–1079.
19. Martin-Vide J., Lopez-Bustins J.A. The Western Mediterranean Oscillation and rainfall in the Iberian Peninsula // Int. J. Climatol. 2006. V. 26. № 11. P. 1455–1475.
20. Maslova V.N., Voskresenskaya E.N., Lubkov A.S., Yurovsky A.V., Zhuravskiy V.Y., Evstigneev V.P. Intense Cyclones in the Black Sea Region: Change, Variability, Predictability and Manifestations in the Storm Activity // Sustainability. 2020. V. 12. № 11. P. 4468.
21. McPhaden M.J., Zebiak S.E., Glantz M.H. ENSO as an integrating concept in Earth science // Sci. 2006. V. 314. № 5806. P. 1740–1745.
22. Mekanik F., Imteaz M.A., Gato-Trinidad S., Elmahdi A. Multiple regression and Artificial Neural Network for long-term rainfall forecasting using large scale climate modes // J. Hydrol. 2013. V. 503. P. 11–21.

23. *Moustris K.P., Larissi I.K., Nastos P.T., Paliatos A.G.* Precipitation Forecast Using Artificial Neural Networks in Specific Regions of Greece // *Water Resour. Manage.* 2011. V. 25. P. 1979–1993.
24. *Nagahamulla H.R.K., Ratnayake U.R., Ratnaweera A.* Monsoon rainfall forecasting in Sri Lanka using artificial neural networks // *Proc. 6th Int. Conf. Ind. Inf. Syst.* 2011. P. 305–309.
25. *Polonsky A.B., Basharin D.V.* How strong is the impact of the Indo-Ocean Dipole on the surface air temperature/sea level pressure anomalies in the Mediterranean region? // *Global and Planetary Change.* 2017. V. 151. P. 101–107.
26. *Redolat D., Monjo R., Lopez-Bustins J.A., Martin-Vide J.* Upper-Level Mediterranean Oscillation index and seasonal variability of rainfall and temperature // *Theor. Appl. Clim.* 2019. V. 135. P. 1059–1077.
27. *Saji N., Goswami B., Vinayachandran P., Yamagata T.* A dipole mode in the tropical Indian Ocean // *Nature.* 1999. V. 401. P. 360–363.
28. *Schlesinger M.E., Ramankutty N.* An oscillation in the global climate system of period 65–70 years // *Nature.* 1994. V. 367. № 6465. P. 723–726.
29. *Shukla R.P., Tripathi K.C., Pandey A.C., Das I.M.L.* Prediction of Indian summer monsoon rainfall using Niño indices: A neural network approach // *Atm. Res.* 2011. V. 102. № 1–2. P. 99–109.
30. *Singh P., Borah B.* Indian summer monsoon rainfall prediction using artificial neural network // *Stoch. Environ. Res. Risk Assess.* 2013. V. 27 P. 1585–1599.
31. *Trenberth K.E., Caron J.M.* The Southern Oscillation Revisited: Sea Level Pressures, Surface Temperatures, and Precipitation // *J. Climate.* 2000. V. 13. P. 4358–4365.
32. *Vallès-Casanova I., Lee S.-K., Foltz G.R., Pelegri J.L.* On the spatiotemporal diversity of Atlantic Nino and associated rainfall variability over West Africa and South America // *Geophys. Res. Letters.* 2020. V. 47. № 8. P. e2020GL087108.
33. *Wallace J.M., Gutzler D.S.* Teleconnections in the geopotential height field during the Northern Hemisphere winter // *Monthly Weather Rev.* 1981. V. 109. P. 784–812.
34. *Xu H.* Modification of Normalised Difference Water Index (NDWI) to Enhance Open Water Features in Remotely Sensed Imagery // *Int. J. of Remote Sensing.* 2006. V. 27 № 14. P. 3025–3033.
35. *Zhang M., Su B., Nazeer M., Bilal M., Qi P., Han G.* Climatic Characteristics and Modeling Evaluation of Pan Evapotranspiration over Henan Province, China // *Land.* 2020. V. 9. № 7. P. 229.
36. *Zhang Y., Wallace J.M., Battisti D.S.* ENSO-like interdecadal variability: 1900–93 // *J. Climate.* 1997. V. 10. P. 1004–1020.